

Abstract

Student: Morten Eidsvåg | **Emne:** LOG650 Forskningsprosjekt | **Arbeidsform:** Individuelt

Etterspørselsprognoser er kritiske for å forebygge legemiddelmangel og overlagring i farmasøytiske forsyningskjeder, men det er begrenset kunnskap om hvilke prognosemodeller som gir best presisjon for paneldatasett med mange SKU-er og kort historikk i en distribusjonslogistisk kontekst. Denne studien sammenligner fire modeller på et anonymisert datasett bestående av 105 farmasøytiske SKU-er over 48 måneder (januar 2022 – desember 2025): naiv sesongprognose, Holt-Winters eksponentiell glatting, ARIMA/SARIMA og XGBoost. Modellene trenes på de første 36 månedene og evalueres på de siste 12 månedene ved hjelp av feilmålene RMSE, MAE og MAPE (median over alle SKU-er).

Resultatene viser at XGBoost global gir lavest samlet prognosefeil (MAPE: 52,19 %; RMSE: 811,24; MAE: 702,95), etterfulgt av ARIMA (MAPE: 57,77 %), Holt-Winters (MAPE: 62,49 %) og naiv prognose (MAPE: 67,50 %). Diebold-Mariano-tester viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA ($DM = 1,766$, $p = 0,078$) eller mellom XGBoost og ARIMA ($DM = -0,779$, $p = 0,436$). Segmentert analyse viser at XGBoost er klart best for SKU-er uten tydelig sesongmønster (MAPE: 51,50 %) og for varelinjer med høyt volum (MAPE: 49,46 %), men presterer svakest for SKU-er med tydelig sesongmønster (79,13 %), der ARIMA og Holt-Winters er mer robuste. Som kontrolleksperiment ble XGBoost også trent individuelt per SKU med de samme 36 treningsobservasjonene som Holt-Winters og ARIMA; XGBoost individuell oppnår MAPE 62,61 % — nesten identisk med Holt-Winters og klart svakere enn global XGBoost. Dette bekrefter at den globale treningsstrategien (pooling) er den primære årsaken til XGBoosts fordel, ikke gradient boosting-arkitekturen alene.

Studien bidrar med fire funn: (1) XGBoost som global modell gir observert forbedring over klassiske tidsseriemodeller, men DM-testen bekrefter ikke statistisk signifikant forskjell fra ARIMA ($p = 0,436$), (2) modellprestasjonene varierer systematisk mellom volum- og sesongmønstersegmenter, (3) ingen av de testede modellparene skiller seg signifikant fra hverandre i DM-test, og (4) et kontrolleksperiment med XGBoost trent individuelt per SKU (MAPE 62,61 %) bekrefter at global pooling — ikke modellarkitekturen — forklarer XGBoosts relative fordel. For virksomheter uten avansert analysekapasitet er Holt-Winters et robust alternativ med lav implementeringskostnad.

Innhold

1.0 Innledning

1.1 Problemstilling

1.2 Avgrensinger

2.0 Teori og litteratur

3.0 Casebeskrivelse

4.0 Metode og data

4.1 Metode
4.2 Data
4.3 Metodiske forutsetninger
5.0 Modelling
6.0 Analytisk rammeverk
7.0 Resultat
8.0 Diskusjon
9.0 Konklusjon
10.0 Bibliografi
Vedlegg

1.0 Innledning

Etterspørselsprognoser er sentrale i beslutningsprosessene innen logistikk og supply chain management. Prognoser danner grunnlaget for planlegging av produksjon, lagerbeholdning og distribusjon i forsyningskjeder (Hyndman & Athanasopoulos, 2021). Den farmasøytiske sektoren kjennetegnes av sesongvariasjoner, regulatoriske krav og høye krav til leveringspålidelighet. I Norge har man gjennom flere tiår bygget ned nasjonale beredskapslagre for legemidler. Tidligere hadde staten et mer direkte ansvar for beredskapslager gjennom Norsk Medisinaldepot (NMD). Etter innføringen av apotekloven 1. mars 2001 så ble dette i noen grad erstattet med minstekrav til leveringsgrad for legemidler (Lov om apotek §5-4).

Til tross for dette har Norge opplevd en betydelig økning i legemiddelmangel de senere årene. I 2023 mottok Statens legemiddelverk 1 403 mangelrapporter, og økningen tilskrives blant annet produksjonsproblemer, logistikkutfordringer og internasjonal ustabilitet i forsyningskjedene (Statens legemiddelverk, 2024). Slike mangelsituasjoner kan skyldes både globale forsyningsproblemer og mangelfulle etterspørselsprognoser. Feilprognoser kan føre til enten legemiddelmangel, med potensielle helsemessige konsekvenser, eller overlagering som gir økte kostnader og risiko for tapt salg.

Tradisjonelt har etterspørselsprognoser vært basert på statistiske tidsseriemodeller som eksponentiell glatting og ARIMA (Hyndman & Athanasopoulos, 2021). Eksponentiell glatting, inkludert Holt–Winters-metoden, er spesielt utviklet for tidsserier som inneholder både trend og sesongmønstre, og er derfor mye brukt i operativ etterspørselsplanlegging (Hyndman & Athanasopoulos, 2021). Innen farmasøytisk industri viser studier at Holt–Winters ofte gir tilfredsstillende prognosenøyaktighet når dataserier inneholder tydelige sesongkomponenter (Burinskiene, 2020).

Nyere forskning indikerer imidlertid at maskinlæringsmetoder kan håndtere mer komplekse og ikke-lineære mønstre i data. Spesielt har gradient boosting-metoder som XGBoost vist gode resultater i prognoseoppgaver hvor tradisjonelle modeller ikke fanger opp komplekse sammenhenger (Chen & Guestrin, 2016; Fourkiotis & Tsadiras, 2024).

Litteraturgjennomgangen viser derfor et metodisk spenn mellom klassiske statistiske modeller og nyere maskinlæringsmetoder. Til tross for et voksende antall studier på maskinlæringsbaserte prognosemetoder, er det få som systematisk sammenligner klassiske statistiske modeller og moderne maskinlæringsmetoder på paneldatasett med mange SKU-er og begrenset historikk i en distribusjonslogistisk kontekst. Eksisterende studier fokuserer ofte på enkeltprodukter, lengre tidsserier eller sektorer med andre etterspørselsmønstre enn det farmasøytiske distribusjonsleddet (Makridakis et al., 2022). Det er derfor et gap i litteraturen knyttet til hvilken modelltype som gir best balanse mellom prognosepresisjon og operasjonell anvendbarhet når datagrunnlaget er begrenset og mange produktlinjer skal prognostiseres simultant.

Denne studien bidrar med en empirisk sammenligning av fire prognosemodeller — naiv sesongprognose, Holt-Winters, ARIMA/SARIMA og XGBoost — på et reelt paneldatasett fra farmasøytisk distribusjon, bestående av 105 SKU-er over 48 måneder. Bidraget er todelt: metodisk ved å anvende et felles evalueringsrammeverk (RMSE, MAE og MAPE) på tvers av alle modeller og produkter, og praktisk ved å gi innsikt i hvorvidt økt modellkompleksitet gir reell merverdi for logistikkplanlegging under begrensede dataforhold.

Problemstilling

Med utgangspunkt i ovenstående aktualisering formuleres følgende problemstilling:

Hvilke prognosemodeller egner seg best for månedlige leveranser av farmasøytiske varelinjer i et sentrallager-grossist-system, og i hvilken grad varierer modellprestasjonene på tvers av produktsegmenter?

For å besvare problemstillingen operasjonaliseres den gjennom tre forskningsspørsmål:

RQ1: Hvilken av de fire modellene — naiv sesongprognose, Holt-Winters, ARIMA/SARIMA og XGBoost — gir lavest prognosefeil (RMSE, MAE, MAPE) i testperioden, målt på tvers av alle 105 SKU-er?

RQ2: Varierer den relative modellprestasjonen mellom produktsegmenter, slik som høy- og lavvolum-SKU-er eller SKU-er med og uten tydelig sesongmønster?

RQ3: I hvilken grad gir økt modellkompleksitet reell merverdi når prognosepresisjon vurderes opp mot implementeringskostnad, tolkningsbarhet og praktisk anvendbarhet i operativ planlegging?

Disse feilmålene er valgt fordi de fanger ulike aspekter ved prognosenøyaktighet: RMSE vektlegger store avvik og er sensitiv for uteliggere, MAE gir et robust absolutt mål som er lettere å tolke

operasjonelt, og MAPE muliggjør sammenligning på tvers av SKU-er med ulik volumskala (Hyndman & Athanasopoulos, 2021).

Avgrensinger

For å sikre analytisk presisjon gjøres følgende avgrensninger:

Datasett: Studien benytter kun historiske leveransedata (månedlig volum fra sentrallager til grossist) — ikke faktisk sluttkundetterspørsel. Leveranser brukes som en proxy for etterspørsel, og dette skillet er sentralt for tolkningen av resultatene (se avsnitt 4.3, Forutsetning 1). Eksterne forklaringsvariabler som pris, kampanjer, demografi eller regulatoriske utfordringer inkluderes ikke, ettersom formålet er å isolere effekten av historisk volum som prediktor og unngå at modellutvalgene påvirkes av uobserverte kovariater.

Tidsperiode: Datasettet dekker totalt 48 måneder (januar 2022 – desember 2025), hvorav 36 måneder benyttes som treningssett og 12 måneder som testsett. Lengre historikk er ikke tilgjengelig fra virksomheten. Splitten er valgt fordi den gir tre hele år til trening og ett helt år til testing, slik at modellene evalueres over en full sesongsyklus.

Prognosehorisont: Fokus er på én måneds fremover-prognose, relevant for operativ lager- og distribusjonsplanlegging. Lengre horisonter er ikke vurdert, da datamengden ikke gir tilstrekkelig grunnlag for pålitelig validering av flertrinns-prognoser.

Modellutvalg: De fire valgte modellene — naiv sesongprognose, Holt-Winters, ARIMA/SARIMA og XGBoost — representerer et spekter fra enkel referansemodell til avansert maskinlæring, i tråd med det metodiske rammeverket benyttet i M5-konkurransen (Makridakis et al., 2022). Dette gjør det mulig å vurdere om økt modellkompleksitet gir reell merverdi, uten å overkomplisere analysen med modeller som krever vesentlig mer data eller domenespesifikk kalibrering.

Analyseenhet: Prognoser utvikles på varelinjenivå (SKU-nivå), siden aggregering til produktgruppe- eller kategorinivå ville maskert vesentlig variasjon i etterspørselsmønstre på tvers av produkter.

Datagrunnlag og anonymisering: Datasettet er anonymisert av virksomheten før utlevering. Produktnavn, kundeinformasjon og prisdata er fjernet, noe som begrenser muligheten til å inkludere forretningskontekst i analysen. Anonymiseringen er nødvendig av konfidensialitetshensyn og påvirker ikke analysens metodiske gyldighet, men begrenser tolkningen av resultatene til volumbaserte mønstre.

Generaliserbarhet: Studien er basert på ett datasett fra én virksomhet i én distribusjonskontekst. Funnene er derfor ikke direkte generaliserbare til andre bransjer, distribusjonsledd eller produktkategorier. Studien har likevel overføringsverdi som metodisk referanse for sammenlignbare datasett med panelstruktur, begrenset historikk og mange SKU-er.

Disse avgrensningene gjør det mulig å analysere modellenes prestasjon under realistiske og sammenlignbare betingelser, samtidig som metodisk etterprøvbarehet opprettholdes.

Studien er gjennomført med støtte av AI-verktøy (Claude, OpenAI) i en *human-in-the-loop*-arbeidsflyt, i tråd med LOG650-emnets rammer for AI-assistert forskningsprosess. AI er benyttet til kodeutvikling, feilsøking, strukturering av analysetrinn og rapportutforming. Studenten har hatt fullt ansvar for problemstilling, datatilgang, metodevalg, tolkning av resultater og faglig kvalitetssikring. Alle analytiske beslutninger — herunder modellvalg, parametersetting og vurdering av statistisk signifikans — er tatt av studenten og begrunnet i rapporten.

Rapporten er strukturert som følger: Avsnitt 2 gjennomgår relevant teori og litteratur om etterspørselsprognoser og prognosemodeller. Avsnitt 3 beskriver caset og datagrunnlaget. Avsnitt 4 redegjør for metode og data, inkludert metodiske forutsetninger. Avsnitt 5 presenterer modelleringen, mens avsnitt 6 beskriver det analytiske rammeverket for evaluering. Avsnitt 7 presenterer resultatene, avsnitt 8 diskuterer funnene i lys av teori og praksis, og avsnitt 9 oppsummerer konklusjonene.

2.0 Teori og litteratur

Dette kapittelet etablerer det teoretiske rammeverket for studien. Gjennomgangen er strukturert i fire deler: generell prognoseteori (2.1), prognoser i farmasøytisk og logistisk kontekst (2.2), maskinlæring og globale modeller (2.3), og uenigheter i forskningen samt plassering av denne studien i litteraturen (2.4).

2.1 Generell prognoseteori

Etterspørselsprognoser er et sentralt forskningsområde innen logistikk og supply chain management, ettersom prognosenøyaktighet direkte påvirker beslutninger knyttet til lagerstyring, produksjonsplanlegging og distribusjon (Hyndman & Athanasopoulos, 2021). Prognoser utvikles typisk ved hjelp av kvantitative metoder som utnytter historiske mønstre i etterspørselsdata — enten gjennom statistiske modeller som eksponentiell glatting og ARIMA, eller gjennom maskinlæringsbaserte metoder som XGBoost (Petroopoulos et al., 2022).

Tradisjonelle prognosemetoder er basert på statistisk tidsserieanalyse og antar at historiske observasjoner inneholder informasjon om fremtidige verdier gjennom trend, sesongmønstre og autokorrelasjon.

Den enkleste formen for sesongbasert prognose er den naive sesongprognosen (seasonal naïve method), som antar at fremtidig etterspørsel tilsvarende verdien fra tilsvarende periode ett år tidligere. For månedlige data er prognosen for periode t lik observasjonen fra periode $t - 12$. Modellen fungerer primært som en referansemodell (benchmark) for å vurdere om mer avanserte metoder faktisk tilfører prediktiv verdi (Hyndman & Athanasopoulos, 2021). I prognoselitteraturen

er det etablert praksis å inkludere en naiv referansem modell i alle komparative evalueringer, ettersom en modell som ikke slår det naive nivået ikke gir grunnlag for implementering (Makridakis et al., 2022).

Holt–Winters-metoden er en videreutvikling av eksponentiell glatting som dekomponerer tidsserien i tre komponenter: nivå, trend og sesong. Metoden er spesielt egnet for dataserier med stabile sesongmønstre og brukes mye i operativ salgs- og lagerprognostisering (Hyndman & Athanasopoulos, 2018).

ARIMA (Autoregressive Integrated Moving Average) beskriver tidsserier gjennom statistiske sammenhenger mellom tidligere observasjoner og prognosefeil. Modellen kan tilpasses fleksibelt til serier uten tydelig sesongstruktur (Box et al., 2015), og studier viser at statistiske modeller fortsatt gir gode resultater ved korte og stabile dataserier (Petroopoulos et al., 2022).

2.2 Prognoser i farmasøytisk og logistisk kontekst

I farmasøytisk sektor er presise prognoser særlig kritiske: feilprognoser kan enten føre til legemiddelmangel med direkte konsekvenser for pasienter, eller til overlagering med økt kapitalbinding og risiko for ukurans. Etterspørselen er i varierende grad sesongpreget — respiratoriske legemidler og vitaminer viser typisk høyere etterspørsel i vinterhalvåret, mens andre produktkategorier har mer stabil etterspørsel gjennom året.

Burinskiene (2020) viser at prognosenøyaktighet i farmasøytisk retail påvirkes like mye av datakvalitet og strukturingsnivå som av selve modellvalget. Prognoser på et mer detaljert nivå i distribusjonsskjeden gir bedre presisjon enn aggregerte analyser, og håndtering av outliers og mangelperioder er avgjørende for pålitelige resultater.

Fourkiotis og Tsadiras (2024) sammenligner statistiske modeller og maskinlæringsmetoder på farmasøytiske salgsdata og finner at XGBoost typisk gir lavere prognosefeil enn tradisjonelle modeller, men at enklere statistiske modeller kan prestere like godt ved tydelige sesongmønstre. Absoluttnivåene for MAPE er høye sammenlignet med forbruksvarer, noe som er konsistent med den høye etterspørselsvariabiliteten og det høye innslaget av lavvolum-produkter som kjennetegner farmasøytisk distribusjon.

2.3 Maskinlæring og globale modeller

I nyere forskning har maskinlæringsmetoder fått stadig mer oppmerksomhet innen etterspørselsprognoser. Disse metodene skiller seg fra tradisjonelle modeller ved at de lærer mønstre direkte fra data uten å forutsette en bestemt statistisk struktur. XGBoost (Extreme Gradient Boosting) er en ensemblemetode basert på gradient boosting av beslutningstrær (Chen & Guestrin, 2016) og har vist sterke resultater i en rekke prediksjonsoppgaver.

En viktig distinksjon i maskinlæringsbasert prognostisering er valget mellom *lokal* og *global* treningsstrategi. En lokal modell trenes individuelt per produkt og utnytter kun den aktuelle varelinjes historikk. En global modell trenes på tvers av alle produkter simultant og kan dermed lære mønstre som er felles for porteføljen — sesongtopper, trendretning og etterspørselsrytme — selv om den individuelle historikken er kort. Zhu et al. (2021) viser at maskinlæringsmodeller kan forbedre prognosenøyaktigheten ytterligere ved å utnytte informasjon på tvers av relaterte tidsserier, særlig relevant for datasett med mange produkter og begrenset historikk per varelinje.

Dette er særlig relevant for datasett som dette: med kun 36 treningsobservasjoner per SKU gir en lokal XGBoost-modell etter laggkonstruksjon kun ~24 brukbare treningsrader — for lite for en trebasert ensemblemetode. En global modell løser dette ved å poole data på tvers av alle 105 SKU-er og gi ~2 520 treningsrader totalt, noe som kompenserer for den korte individuelle historikken. Dette prinsippet — kjent som *cross-learning* eller *global pooling* — er en sentral mekanisme bak de best plasserte løsningene i M5-konkurransen (Makridakis et al., 2022). Implikasjonen er at XGBoosts relative fordel i dette datasettet forventes å stamme fra pooling-effekten, ikke fra gradient boosting-arkitekturen alene — en hypotese som testes eksplisitt i studien (avsnitt 8.3).

2.4 Uenigheter i forskningen og plassering av studien

Til tross for den økte interessen for maskinlæringsmetoder er det fortsatt uenighet i litteraturen om hvorvidt slike metoder alltid er overlegne tradisjonelle modeller. Petropoulos et al. (2022) viser at enklere modeller kan prestere like godt eller bedre ved korte og relativt stabile dataserier. En sentral diskusjon handler om forholdet mellom modellkompleksitet og praktisk nytte: mer avanserte modeller er vanskeligere å implementere og tolke, og økt kompleksitet gir ikke nødvendigvis bedre beslutningsgrunnlag i operative planleggingsprosesser.

De gjennomgåtte studiene etterlater flere ubesvarte spørsmål som er relevante for denne studien. Burinskiene (2020) analyserer prognoser i farmasøytisk retail, men dekker ikke distribusjonsleddet mellom sentrallager og grossist. Fourkiotis og Tsadiras (2024) sammenligner statistiske og maskinlæringsbaserte metoder på farmasøytiske data, men benytter ikke en naiv sesongprognose som referansem modell og inkluderer ikke Diebold-Mariano-testing for å vurdere statistisk signifikans i modellforskjeller. Zhu et al. (2021) demonstrerer verdien av tverrproduktlæring, men fokuserer på supply chain-data med eksogene variabler som ikke er tilgjengelig i dette studiet. Petropoulos et al. (2022) gir en bred oversikt over prognoselitteraturen, men gir ikke empiriske resultater for det spesifikke dataformatet — månedlige paneldata med 105 SKU-er og 48 måneders historikk — som benyttes her.

Denne studien fyller dette gapet ved å kombinere et felles evalueringsrammeverk med statistisk testing på et reelt distribusjonsdatasett, ved å analysere om modellprestasjonene er stabile på tvers av produktsegmenter, og ved å isolere pooling-effekten gjennom et kontroll eksperiment med individuell XGBoost-trening.

3.0 Casebeskrivelse

Studien tar utgangspunkt i en anonymisert farmasøytisk virksomhet som importerer og distribuerer legemidler fra et europeisk sentrallager til grossister i Norge. Virksomheten opererer i et strengt regulert marked der apotekloven setter minstekrav til leveringsgrad og tilgjengelighet (Lov om apotek, 2000). Høy leveringspålitelighet er derfor ikke bare et kommersielt mål, men et regulatorisk krav.

Forsyningskjedestruktur

Distribusjonskjeden i dette caset følger en flertrinns struktur: sentrallager eksporterer til norske grossister, som videreleverer til apotek, som igjen ekspederer til sluttbruker (pasient). Prognosene som utvikles i denne studien gjelder leveranser på det første leddet — fra sentrallager til grossist — og representerer dermed engrosetterspørselen i den norske markedskanalen. Feil på dette leddet forplanter seg nedover i kjeden: for lav prognose gir mangel hos grossist og risiko for tomme apotekhyller, mens for høy prognose gir overlaging med kapitalbinding og mulig ukurans for produkter med begrenset holdbarhet (Zhu et al., 2021).

Sesongvariasjon og etterspørselsdrivere

Etterspørselen etter farmasøytiske produkter er i varierende grad sesongpreget. Respiratoriske legemidler og vitaminer viser typisk høyere etterspørsel i vinterhalvåret som følge av influensasesong og økt forekomst av luftveisinfeksjoner. Andre produktkategorier har mer stabil etterspørsel gjennom året. For denne studien er sesongstruktur særlig relevant fordi tre av de fire modellene — Holt-Winters, ARIMA/SARIMA og naiv sesongprognose — eksplisitt modellerer sesongkomponenten, mens XGBoost lærer sesongmønstre implisitt gjennom kalenderbaserte kjennetegn. Datasettets 105 SKU-er representerer et bredt spekter av disse mønstrene, fra tydelig sesongvariasjon til flat etterspørsel.

Datagrunnlag

Datasettet består av månedlige leveransevolumer for 105 varelinjer over perioden januar 2022 til desember 2025 — totalt 48 måneder og om lag 5 040 observasjoner. Dataene er hentet fra virksomhetens ERP-system og representerer faktiske leveranser fra sentrallager til grossist, ikke prognostisert eller justert etterspørsel. Datasettet er anonymisert av kontaktpersonen i virksomheten før utlevering, slik at produktnavn og annen identifiserende informasjon er fjernet.

Forskerposisjon

Studenten er ansatt i virksomheten og har hentet datasettet direkte fra ERP-systemet. Insiderposisjonen medfører både fordeler og ulemper som er relevante for vurderingen av studiens gyldighet.

Fordelene er substansielle: studenten har førstehånds kjennskap til dataenes opprinnelse, mulige feilkilder og operasjonell kontekst. Dette gjør det mulig å vurdere om enkeltobservasjoner skyldes reell variasjon eller registreringsfeil, og å tolke resultatene i lys av faktiske forretningsprosesser — kunnskap som ikke er tilgjengelig for en ekstern forsker. Innsikten i distribusjonsskjedens struktur, leveransesykluser og produktporteføljens sammensetning er direkte relevant for tolkningen av modellenes styrker og svakheter.

Ulempen er risikoen for konfirmasjonsskjevhet, der studenten ubevisst tolker resultater i tråd med egne forventninger (Bryman, 2012). For å redusere denne risikoen er analysen gjennomført med et fast evalueringsrammeverk definert før modellering, og alle parametere og resultater er dokumentert i versjonskontrollert kode uten manuell justering av utfall. Bruken av AI-verktøy i analyse og strukturering bidrar i tillegg til at databehandlingen er reproduserbar og uavhengig av studentens forhåndsoppfatninger. Virksomhetens egne interne prognosemodeller er ikke tilgjengelige for studenten og inngår ikke i analysen.

4.0 Metode og data

Studien er gjennomført som en kvantitativ casestudie basert på historiske leveransedata fra én virksomhet. Formålet er å sammenligne prognosepresisjon på tvers av fire modeller ved bruk av identiske data og evalueringsmetoder.

Forskningsdesign

Studien følger et komparativt evalueringsdesign der fire prognosemodeller — naiv, Holt-Winters, ARIMA og XGBoost — sammenlignes på det samme datasettet under identiske betingelser. Designet er i tråd med standard evalueringspraksis i tidsserieprognostisering, der modeller evalueres ved hjelp av felles feilmål og hold-out-validering (Hyndman & Athanasopoulos, 2021).

Kvantitativ metode

Studien er utelukkende kvantitativ og tar utgangspunkt i et positivistisk forskningsperspektiv der virkeligheten antas å kunne måles og modelleres gjennom numeriske observasjoner (Bryman, 2012). Formålet er ikke å forstå sosiale mekanismer, men å evaluere modellprestasjoner på

historiske data — et spørsmål som besvares best gjennom statistisk analyse og reproducerbare eksperimenter.

Studien er gjennomført som en kvantitativ casestudie, der ett spesifikt datasett fra én virksomhet analyseres i dybden. Casestudiedesignet er valgt fordi det gir tilgang til reelle operasjonelle data og muliggjør metodisk kontroll, selv om ekstern generaliserbarhet er begrenset (Bryman, 2012). Det er ikke gjennomført intervjuer, spørreundersøkelser eller kvalitativ analyse.

Analyseverktøy

Analysen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `pmdarima`, `xgboost`, `pandas`, `numpy`, `matplotlib` og `scikit-learn`. Python er valgt fordi det gir fri tilgang til oppdaterte implementasjoner av alle fire modellene, og fordi analysekoden kan gjøres transparent og reproducerbar.

Etiske betraktninger

Datasettet er anonymisert av studenten i tråd med virksomhetens retningslinjer for bruk av data i KI-verktøy og akademisk forskning. Anonymiseringen sikrer at hverken produktidentitet eller bedriftsinformasjon kan identifiseres av tredjeparter.

4.1 Bruk av kunstig intelligens i forskningsprosessen

I tråd med LOG650-emnets rammer er kunstig intelligens benyttet som støtteverktøy gjennom hele forskningsprosessen. Bruken er basert på en *human-in-the-loop*-tilnærming der studenten har beholdt fullt faglig ansvar for alle sentrale beslutninger, mens AI har bistått med operativt og teknisk arbeid.

AI-verktøyene ble benyttet til:

- Kodeutvikling i Python, herunder implementering av prognosemodeller, featurebygging, krysskalibrering og visualisering
- Feilsøking og optimalisering av analysekode
- Strukturering av rapport og faglig bearbeiding av tekst
- Forklaring av modellteori og metodiske valg underveis i prosessen

Studenten hadde fullt ansvar for:

- Definisjon av problemstilling, forskningsspørsmål og avgrensninger
- Innhenting og anonymisering av datasettet fra virksomhetens ERP-system
- Valg av modeller, evalueringsmetrikker og analytisk rammeverk

- Tolkning av resultater og vurdering av statistisk signifikans
- Faglig kvalitetssikring av alle konklusjoner

AI-generert innhold — enten kode, tekstutkast eller metodiske forklaringer — ble ikke brukt ukritisk, men alltid vurdert opp mot relevant teori, faktiske resultater og studentens egne faglige vurderinger. Alle analyseresultater er reproducerbare fra den versjonskontrollerte koden og det anonymiserte datasettet, uavhengig av hvilke AI-verktøy som har vært benyttet i prosessen.

4.2 Data

Datasettet er beskrevet i detalj i avsnitt 3.0 (Casebeskrivelse). Her beskrives de metodiske valgene knyttet til databehandling og datastruktur.

Leveransene fra sentrallager til grossist brukes som en proxy for faktisk etterspørsel i markedet. Dette er en sentral forutsetning som diskuteres nærmere i avsnitt 4.3 (Forutsetning 1). Proxy-tilnærmingen er vanlig i kvantitative studier av forsyningskjededata der sluttbrukernes faktiske etterspørsel ikke er direkte observerbar (Zhu et al., 2021).

Innsamling av data

Dataene er hentet direkte fra virksomhetens ERP-system av studenten som arbeider i virksomheten. Uttrekket ble gjort som en eksport av historiske salgsdata til Excel-format. Før analysen ble datasettet anonymisert slik at produktidentitet og bedriftsinformasjon ikke kan identifiseres.

Det er ikke gjennomført intervjuer eller spørreundersøkelser i forbindelse med datainnsamlingen. All kvantitativ analyse i studien baseres på historiske salgsdata.

Tidsperiode og datastruktur

Datasettet dekker perioden **januar 2022 – desember 2025**, noe som gir **48 månedlige observasjoner per varelinje**. Alle 105 SKU-er er til stede i hele perioden — ingen varelinjer ble fjernet fra analysen.

Datasettets innhold og datarensing

Rådatasettet inneholder nøyaktig **5 040 observasjoner (105 SKU-er × 48 måneder)**. Datarensingen besto av følgende konkrete steg:

- **Ikke-numeriske verdier** ble konvertert til NaN ved innlasting og deretter satt til 0. Dette gjaldt perioder uten registrert leveranse, tolket som reelt nullsalg.
- **Ingen observasjoner ble fjernet** fra tidsseriene. Alle 5 040 observasjoner inngår i analysen.
- **Ingen SKU-er ble ekskludert.** Alle 105 varelinjer har komplette tidsserier på 48 måneder etter rensing.
- **Nullverdier beholdt:** 80 av 105 SKU-er (76,2 %) har minst én månedlig observasjon med nullverdi. Disse er beholdt som gyldige observasjoner og representerer perioder uten leveranse. MAPE-beregningen ekskluderer perioder der $y_t = 0$ for å unngå divisjon på null (jf. avsnitt 4.3, Forutsetning 5).
- **Ingen outlier-fjerning** ble gjennomført. Ekstreme enkeltobservasjoner er beholdt for å reflektere faktisk etterspørselsvariasjon.

Tilgang til data

Datasettet er hentet fra virksomhetens interne ERP-system og kan derfor ikke gjøres offentlig tilgjengelig i sin opprinnelige form. De anonymiserte dataene er kun brukt til analyse i denne studien. Strukturen i datasettet og metodene som er brukt i analysen er imidlertid beskrevet slik at tilsvarende analyser kan gjennomføres på andre datasett med tilsvarende struktur.

Beskrivelse av datasettet

Variabel	Beskrivelse
Antall produkter (SKU)	105
Datakilde	ERP-system
Geografisk område	Norge
Distribusjonsledd	Europeisk sentrallager til grossister i Norge
Tidsperiode	Jan 2022 – Des 2025
Observasjonsnivå	Måned
Maks observasjoner per SKU	48
Totalt antall potensielle observasjoner	5 040

4.3 Metodiske forutsetninger

For å sikre pålitelighet i analysen legges følgende forutsetninger til grunn. Forutsetningene avgrenser også tolkningen av resultatene.

Forutsetning 1: Leveranser reflekterer virkelig etterspørsel

Det antas at månedlige leveranser fra sentrallager til grossister i hovedsak reflekterer faktisk etterspørsel, og at leveransene ikke systematisk påvirkes av hamstring, kampanjer eller regulatoriske forhold. Bullwhip-effekten — tendensen til at variasjoner i bestillingsatferd forsterkes oppover i forsyningskjeden — kan likevel medføre at leveransevolumene overestimerer den reelle sluttbrukeretterspørselen (Lee et al., 1997). Denne forutsetningen er akseptabel for formålet med studien, ettersom analysens mål er å prognostisere grossistetterspørsel, ikke sluttbrukernes etterspørsel.

Forutsetning 2: Stabile mønstre i treningsperioden

Trend- og sesongkomponenter antas å være relativt stabile i treningsperioden på 36 måneder. Strukturelle brudd eller regimeendringer i data vil kunne redusere prognoseevnen til samtlige modeller (Hyndman & Athanasopoulos, 2021).

Forutsetning 3: Modellering av varelinjer

For de klassiske modellene — naiv sesongprognose, Holt-Winters og ARIMA/SARIMA — modelleres hver varelinje uavhengig av øvrige produkter. Krysselastisiteter og substitusjonseffekter inngår ikke eksplisitt i disse modellene, i tråd med standard praksis i klassisk tidsserieprognostisering (Hyndman & Athanasopoulos, 2021). XGBoost er derimot implementert som en global modell trent på tvers av alle 105 SKU-er simultant, og kan dermed implisitt lære mønstre som er felles for flere varelinjer. Dette er en bevisst metodisk asymmetri som diskuteres i kapittel 8.

Forutsetning 4: Univariate modeller er tilstrekkelige

Alle fire modeller er univariate og inkluderer ikke eksterne forklaringsvariabler som pris, kampanjer eller regulatoriske endringer. Dette er et bevisst valg begrunnet i avgrensningene i avsnitt 1.2. Forutsetningen er at historiske leveransemønstre inneholder tilstrekkelig informasjon for kortsiktig prognostisering i et stabilt distribusjonssystem. Petropoulos et al. (2022) viser at univariate modeller generelt presterer konkurransedyktig for kortsiktige prognoser når de

underliggende tidseriene er relativt stabile — noe som støtter gyldigheten av denne forutsetningen for dette datasettet.

Forutsetning 5: Feilmålenes gyldighet

Det antas at prognoseavvikene ikke inneholder vedvarende systematisk over- eller underestimering, slik at feilmålene RMSE, MAE og MAPE gir meningsfull sammenligning mellom modellene.

MAPE er imidlertid metodisk sårbart i dette datasettet. Målet er udefinert når $y_t = 0$ og ustabilt for lavvolum-SKU-er, der små absolutte avvik gir svært høye prosentverdier (Hyndman & Athanasopoulos, 2021). Med 80 av 105 SKU-er (76,2 %) med minst én nullverdi i tidsserien er dette ikke et marginalet problem, men et strukturelt trekk ved datasettet. To tiltak er gjennomført for å begrense effekten: (1) perioder med $y_t = 0$ ekskluderes fra MAPE-beregningen per varelinje, og (2) median benyttes fremfor gjennomsnitt ved aggregering på tvers av SKU-er, noe som reduserer påvirkningen fra ekstreme enkeltobservasjoner.

Disse tiltakene reduserer, men eliminerer ikke, MAPEs svakhet på dette datasettet. Alternative feilmål som sMAPE (Symmetric MAPE) og MASE (Mean Absolute Scaled Error) er mer robuste ved nullverdier og asymmetriske fordelinger (Hyndman & Koehler, 2006), men er ikke inkludert i denne studien for å begrense omfanget. Bruk av slike mål er et naturlig steg i videre forskning på tilsvarende datasett.

Samlet innebærer forutsetningene at studiens resultater primært gjelder stabile distribusjonssystemer uten større strukturelle brudd, og at MAPE-verdiene bør tolkes relativt mellom modeller fremfor som absolutte mål på prognosepresisjon.

5.0 Modellering

5.1 Modelleringsrammeverk

Modelleringen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `pmdarima`, `xgboost` og `pandas`. Alle modeller er implementert og evaluert etter et felles rammeverk for å sikre sammenlignbarhet på tvers av metodene.

Datasettet er delt inn i et treningssett og et testsett ved hjelp av en *hold-out*-strategi. Treningssettet består av de første 36 månedene (januar 2022 – desember 2024), mens testsettet består av de siste 12 månedene (januar 2025 – desember 2025). Denne inndelingen er valgt fordi testperioden dekker én full sesongssyklus, noe som gjør det mulig å evaluere modellenes evne til å predikere sesongvariasjoner. Hold-out-evaluering er i tråd med standard praksis i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Alle 105 varelinjer modelleres separat for de individuelle modellene (naiv, Holt-Winters, ARIMA), i tråd med forutsetningen om uavhengige tidsserier. XGBoost trenes som en global modell på tvers av alle varelinjer.

Prognosestrategi og evalueringshorisont: Testperioden dekker 12 måneder (januar–desember 2025), og alle modeller produserer *out-of-sample*-prognoser for hele denne perioden. Det er viktig å skille mellom to begreper som brukes i rapporten:

- *Prognosehorisont* på 12 måneder betyr at modellene evalueres på 12 påfølgende måneder etter treningsperiodens slutt (desember 2024). Dette er evalueringsvinduet, ikke en 12-måneders direkteprognose laget i ett steg.
- *Operativ prognoseenhet* er én måned av gangen: modellene predikerer én periode frem i tid per steg.

Naiv, Holt-Winters og ARIMA/SARIMA benytter en **direkte flertrinns-strategi**: modellen tilpasses treningssettet og genererer alle 12 prognoseperioder i ett kall fra slutten av treningsperioden. XGBoost (både global og individuell) benytter en **rekursiv én-steps-strategi**: modellen predikerer én måned frem, den predikerte verdien legges til historikken, og prosessen gjentas 12 ganger. Denne strategien er nødvendig fordi XGBoost bruker laggede observasjoner som input, og laggværddier for fremtidige perioder ikke er observert. Rekursiv prognose innebærer at prognosefeil kan akkumuleres over horisonten, noe som er en metodisk asymmetri mellom XGBoost og de øvrige modellene.

5.2 Evalueringsmål

Modellene evalueres ved hjelp av tre komplementære feilmål. La y_t være observert verdi og $\hat{y}_t$ være prognosen i periode t , over n perioder i testsettet.

RMSE (Root Mean Squared Error) straffer store avvik strengt gjennom kvadrering og er sensitiv for ekstremverdier:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

MAE (Mean Absolute Error) er robust mot ekstremverdier og gir et intuitivt mål på gjennomsnittlig absolutt avvik:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

MAPE (Mean Absolute Percentage Error) uttrykker prognosefeil som andel av faktisk verdi og muliggjør sammenligning på tvers av varelinjer med ulike volumnivåer:

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

Feilmålene beregnes per varelinje og aggregeres til medianverdier på tvers av alle 105 SKU-er. Median benyttes fremfor gjennomsnitt fordi fordelingen av feilmål forventes å inneholde ekstreme verdier for varelinjer med lavt volum eller uregelmessig etterspørsel. Begrensninger knyttet til MAPE ved nullverdier og lavvolum-SKU-er er diskutert i avsnitt 4.3 (Forutsetning 5).

5.3 Naiv prognose (referansemodell)

Den naive prognosen benyttes som referansepunkt (*baseline*) og representerer det enkleste mulige prognosealternativet. Modellen predikerer etterspørsel i periode $t + h$ som lik observert etterspørsel i tilsvarende måned foregående år:

$$\hat{y}_{t+h} = y_{t+h-m}$$

der $m = 12$ er sesonglengden (månedlige data) og $h \in \{1, \dots, 12\}$ er prognosehorisont. Modellen fanger opp sesongmønsteret direkte fra historikken uten estimering av parametere, og er derfor fullstendig reproducerbar uten kalibrering. Alle øvrige modeller forventes å gi lavere prognosefeil enn denne referansen (Hyndman & Athanasopoulos, 2021).

5.4 Holt-Winters eksponentiell glatting

Holt-Winters-metoden er en videreutvikling av enkel eksponentiell glatting og modellerer tidsserien ved å dekomponere den i tre komponenter: nivå (ℓ_t), trend (b_t) og sesong (s_t). Metoden estimerer glattingsparametrene α , β og γ , der hver parameter kontrollerer vektingen mellom nyere og eldre observasjoner for sin respektive komponent.

Valget mellom **additiv** og **multiplikativ** sesongkomponent gjøres individuelt per varelinje basert på variasjonskoeffisienten (CV = standardavvik / gjennomsnitt) beregnet på treningssettet. Der $CV > 0,5$ — det vil si der sesongvariasjonen er stor relativt til gjennomsnittlig nivå — benyttes multiplikativ form, ettersom sesongamplituden da er proporsjonal med nivået. Ellers benyttes additiv form. Denne tommelfingerregelen er i tråd med anbefalt praksis i prognoselitteraturen (Hyndman & Athanasopoulos, 2021).

Additiv Holt-Winters (konstant sesongamplitude):

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma(y_t - \ell_t) + (1 - \gamma)s_{t-m}$$

$$\hat{y}_{t+h} = \ell_t + h b_t + s_{t+h-m}$$

Multiplikativ Holt-Winters (sesongamplitude proporsjonal med nivå):

$$\ell_t = \alpha \left(\frac{y_t}{s_{t-m}} \right) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma \left(\frac{y_t}{\ell_t} \right) + (1 - \gamma)s_{t-m}$$

$$\hat{y}_{t+h} = (\ell_t + h b_t) \cdot s_{t+h-m}$$

der $\alpha, \beta, \gamma \in [0, 1]$ og $m = 12$. Parameterne estimeres automatisk ved minimering av SSE (*sum of squared errors*) over treningssettet ved hjelp av `ExponentialSmoothing` fra `statsmodels`.

5.5 ARIMA / SARIMA

ARIMA-modellen (Autoregressive Integrated Moving Average) beskriver en tidsserie gjennom tre komponenter: autoregresjon (AR) av orden p , differensiering d ganger for å oppnå stasjonaritet, og glidende gjennomsnitt (MA) av orden q . Den generelle $ARIMA(p, d, q)$ -modellen er:

$$\phi_p(B)(1 - B)^d y_t = c + \theta_q(B) \varepsilon_t$$

der B er tilbakeskiftoperatoren ($By_t = y_{t-1}$), $\phi_p(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ er det autoregressive polynomet, $\theta_q(B) = 1 - \theta_1 B - \dots - \theta_q B^q$ er MA-polynomet, c er en konstant og $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ er hvit støy.

For månedlige data med sesongstruktur utvides modellen til en sesongutvidet **SARIMA** $(p, d, q)(P, D, Q)_{12}$:

$$\Phi_P(B^{12})\phi_p(B)(1 - B^{12})^D(1 - B)^d y_t = \Theta_Q(B^{12})\theta_q(B) \varepsilon_t$$

der Φ_P og Θ_Q er de sesongmessige AR- og MA-polynomene, og D er antall sesongdifferensieringer.

Stasjonaritet kontrolleres med ADF-testen (*Augmented Dickey-Fuller*) før modellering. Optimale parametre (p, d, q) og (P, D, Q) identifiseres automatisk via AIC-minimering ved hjelp av `auto_arima` fra `pmdarima`.

5.6 XGBoost

XGBoost (Extreme Gradient Boosting) er en ensemblemetode som bygger en additiv modell av K beslutningstrær f_k , der hver prognose er:

$$\hat{y}_t = \sum_{k=1}^K f_k(\mathbf{x}_t), \quad f_k \in \mathcal{F}$$

der $\mathcal{F}$ er rommet av beslutningstrær med regularisering. Modellen minimerer en regularisert tapsfunksjon:

$$\mathcal{L} = \sum_t \ell(y_t, \hat{y}_t) + \sum_{k=1}^K \Omega(f_k)$$

der $\Omega(f_k) = \gamma T_k + \frac{1}{2} \lambda \|w_k\|^2$ straffer antall blader T_k og bladvektene w_k , og ℓ er kvadratisk tapsfunksjon (Chen & Guestrin, 2016).

Ettersom XGBoost ikke modellerer tidsserier direkte, transformeres problemet til en supervisert læringsoppgave. Følgende featurevektor konstrueres for hver observasjon (t , sku):

$$\mathbf{x}_t = [y_{t-1}, y_{t-2}, y_{t-3}, y_{t-12}, \text{måned}_t, t]$$

Lagg-variablene er valgt ut fra autokorrelasjonsmønsteret i treningssettet: y_{t-1} , y_{t-2} og y_{t-3} fanger opp kortsiktig autokorrelasjon og glattingseffekter, mens y_{t-12} fanger opp sesongstrukturen direkte. Mellomliggende lag (y_{t-4} til y_{t-11}) viste lav autokorrelasjon i ACF-analysen og ble utelatt for å redusere risikoen for overfitting i en modell med begrenset treningsdatamengde. $\text{måned}_t \in \{1, \dots, 12\}$ er en kategorisk sesongindikator som supplerer y_{t-12} , og t er en lineær tidsindeks for trend.

Modellen trenes som en **global modell** på alle 105 varelinjer samlet, noe som gjør det mulig å utnytte mønstre på tvers av produkter. Hyperparametrene — antall trær (`n_estimators`), læringsrate (`learning_rate`) og treedybde (`max_depth`) — optimaliseres via tidsseriekrysskalibrering (*time series cross-validation*) på treningssettet med 3 folder.

6.0 Analytisk rammeverk

6.1 Utforskende dataanalyse

Før modellering gjennomføres en utforskende dataanalyse (*exploratory data analysis*, EDA) for å kartlegge egenskapene til tidsseriene. Formålet er å danne et empirisk grunnlag for modelleringsvalg og for tolkning av resultatene.

Følgende elementer inngår i den utforskende analysen:

- **Visualisering av tidsserier:** Utvalgte varelinjer plottes for å identifisere trend, sesongmønstre og eventuelle strukturelle brudd i dataperioden.
- **Dekomponering:** Tidsseriene dekomponeres i komponentene nivå, trend og sesong ved bruk av STL-dekomponering (*Seasonal and Trend decomposition using Loess*) for å kartlegge om sesongmønsteret er stabilt over tid (Cleveland et al., 1990).
- **Stasjonaritetstesting:** ADF-testen (*Augmented Dickey-Fuller*) benyttes for å vurdere om seriene er stasjonære, som er en forutsetning for ARIMA-modellering (Said & Dickey, 1984).

- **Beskrivende statistikk:** Gjennomsnitt, standardavvik og variasjonskoeffisient beregnes per varelinje for å beskrive spredningen i etterspørsel på tvers av produktporteføljen.

Den utforskende analysen gjennomføres på treningssettet alene for å unngå datalekkasje (*data leakage*) fra testsettet inn i modellutformingen.

6.2 Evalueringsdesign

Alle fire modeller evalueres etter et felles evalueringsdesign med identisk train/test-split (36/12 måneder) og prognosehorisont (12 måneder). Feilmål og aggregeringsmetode er beskrevet i avsnitt 5.2.

6.3 Klassifisering av tidsserier

For å nyansere analysen klassifiseres tidsseriene i undergrupper basert på etterspørselskarakteristika. Dette gjøres for å undersøke om modellenes relative prestasjon varierer med egenskapene til dataseriene, og adresserer direkte RQ2 i problemstillingen. Klassifiseringen gjennomføres langs to dimensjoner:

- **Volumnivå:** SKU-ene deles i tre like store grupper (tertiler) basert på gjennomsnittlig månedlig etterspørsel i treningssettet — lav (nederste tertil), middels og høy (øverste tertil).
- **Sesongstyrke:** Styrken av sesongkomponenten beregnes fra STL-dekomponeringen som $F_s = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right)$, der S_t er sesongkomponenten og R_t er residualen. Intuitivt måler F_s hvor stor andel av variasjonen i tidsserien som forklares av sesongmønsteret: $F_s = 1$ betyr at all variasjon er sesongdrevet, $F_s = 0$ betyr at sesongkomponenten ikke bidrar utover residualstøy. SKU-er med $F_s \geq 0,64$ klassifiseres som «sterk sesong», øvrige som «svak sesong». Terskelen på 0,64 er hentet fra M4-konkurransen (Makridakis et al., 2022), der den samme grensen ble brukt til å skille sesongpregede fra ikke-sesongpregede tidsserier i en tilsvarende komparativ evaluering.

Resultatene analyseres både samlet og per undergruppe for å avdekke om én modell er konsistent overlegen, eller om ulike modeller er best egnet for ulike typer varelinjer.

6.4 Statistisk sammenligning

For å vurdere om forskjellene mellom modellenes prognosepresisjon er statistisk signifikante, gjennomføres **Diebold-Mariano-tester** (Diebold & Mariano, 1995) for to sammenligningspar. DM-testen brukes for å undersøke om forskjellen i prognosefeil mellom to modeller er større enn det som kan forventes av tilfeldig variasjon — med andre ord om én modell er systematisk bedre, eller om forskjellen like gjerne skyldes støy i dataene.

Testen gjennomføres for:

- **HW vs. ARIMA:** De to klassiske modellene med likest ytelse sammenlignes for å vurdere om den økte kompleksiteten i ARIMA gir signifikant forbedring over Holt-Winters.
- **XGBoost vs. ARIMA:** Den beste ML-modellen sammenlignes mot den beste klassiske modellen for å vurdere om maskinlæring gir statistisk signifikant merverdi.

Testen beregner en DM-statistikk basert på differansen i kvadrerte prognosefeil per periode, og null-hypotesen er at de to modellene har lik forventningsverdi for prognosenøyaktighet. Signifikansnivå settes til $\alpha = 0,05$. Testen gjennomføres på aggregerte feilserier på tvers av alle 105 SKU-er.

7.0 Resultat

Dette kapittelet presenterer resultatene fra den utforskende dataanalysen og sammenligningen av prognosemodellene. Resultatene presenteres deskriptivt med korte resultatkommentarer der det er nødvendig for å beskrive mønsteret i tabellene. Full tolkning og diskusjon følger i kapittel 8.0.

7.1 Utforskende dataanalyse


Den utforskende analysen viser at de 105 varelinjene varierer betydelig i etterspørselsnivå og mønster. Tabell 1 oppsummerer beskrivende statistikk for hele produktporteføljen over treningsperioden.

Tabell 1: Beskrivende statistikk for treningssettet (Jan 2022 – Des 2024)

Statistikk	Verdi
Antall SKU-er	105
Median månedlig etterspørsel (pakninger)	1 022
Gjennomsnittlig månedlig etterspørsel	2 521
Andel SKU-er med tydelig sesongmønster	70,5 %
Andel SKU-er med positiv trend	53,3 %
Andel SKU-er med nullverdier i tidsserien	76,2 %

Figur 1 viser prognosene for alle fire modeller sammenlignet med faktisk etterspørsel for én varelinje i testperioden. SKU-en er valgt rent illustrativt — den er den andre varelinjen i datasettet, ikke selektert ut fra spesifikke egenskaper som sesongstyrke eller volum. Formålet er å gi et visuelt

inntrykk av hvordan modellenes prognoser forholder seg til faktisk etterspørsel i testperioden, og er ikke representativt for alle 105 SKU-er.



Figur 1: Eksempel på prognose for én varelinje sammenlignet med faktisk etterspørsel i testperioden (Jan–Des 2025)

Datasettet inneholder 105 varelinjer med månedlige observasjoner over perioden januar 2022 til desember 2025 (48 måneder totalt). Etter datarensing besto alle 105 tidsserier av komplette observasjoner egnet for modellering.

Den høye andelen SKU-er med nullverdier (76,2 %) er et viktig karaktertrekk ved datasettet. Nullverdier oppstår primært ved midlertidig ingen leveranse — enten som følge av reelt nullsalg eller periodiske leveringsstopp. Dette påvirker MAPE-beregningene direkte, ettersom MAPE er udefinert når $y_t = 0$. I analysen håndteres dette ved å ekskludere perioder med $y_t = 0$ fra MAPE-beregningen per varelinje, og ved å benytte median fremfor gjennomsnitt ved aggregering, som beskrevet i avsnitt 4.3 (Forutsetning 5).

7.2 Prognosepresisjon — samlede resultater


Tabell 2 presenterer medianverdiene for RMSE, MAE og MAPE på tvers av alle 105 varelinjer i testperioden (Jan 2025 – Des 2025).

Tabell 2: Samlet prognosepresisjon per modell (median over 105 SKU-er, testperiode Jan–Des 2025)

Modell	RMSE	MAE	MAPE (%)
Naiv (sesongnaiv)	1131,65	914,58	67,50
Holt-Winters	935,84	769,90	62,49
XGBoost (individuell)	949,67	845,80	62,61
ARIMA / SARIMA	846,20	820,01	57,77
XGBoost (global)	811,24	702,95	52,19

Merk: XGBoost (individuell) er trent separat per SKU på de samme 36 treningsobservasjonene som Holt-Winters og ARIMA, og inkluderes som kontroll eksperiment for å isolere pooling-effekten.

Figur 2 viser median MAPE per modell og illustrerer den relative forbedringen fra naiv prognose til XGBoost global, samt plasseringen av XGBoost individuell mellom Holt-Winters og ARIMA.



Figur 2: Median MAPE per modell — sammenligning av prognosemodeller i testperioden

7.3 Resultater per undergruppe

Tabell 3 viser median MAPE fordelt på varelinjer med henholdsvis tydelig og svakt sesongmønster, klassifisert ved STL-basert sesongstyrke $F_s \geq 0,64$ (jf. avsnitt 6.3).

Tabell 3: Median MAPE etter sesongstyrke ($F_s \geq 0,64$ = tydelig)

Modell	Tydelig sesong	Svak/ingen sesong
Naiv	71,92 %	67,49 %
Holt-Winters	65,82 %	61,01 %
ARIMA	69,86 %	56,52 %
XGBoost (global)	79,13 %	51,50 %

Tabell 4 viser tilsvarende sammenligning fordelt på volumnivå (høy, middels, lav), basert på tertilgrenser for gjennomsnittlig månedlig etterspørsel i treningssettet (jf. avsnitt 6.3).

Tabell 4: Median MAPE etter volumnivå

Modell	Høyt volum	Middels volum	Lavt volum
Naiv	58,85 %	67,50 %	86,07 %
Holt-Winters	61,01 %	63,63 %	62,49 %
ARIMA	54,91 %	57,77 %	61,48 %
XGBoost (global)	49,46 %	53,32 %	66,61 %

Et sentralt mønster i Tabell 4 er at XGBoost oppnår lavest MAPE i høyvolumsegmentet (49,46 %), men høyest MAPE blant de sesongpregede SKU-ene (Tabell 3: 79,13 %). Holt-Winters og ARIMA viser mer jevn prestasjon på tvers av volumnivåer. Hva dette mønsteret skyldes, diskuteres i avsnitt 8.3.

7.4 Statistisk test

Diebold-Mariano-tester er gjennomført for to sammenligningspar i tråd med evalueringsdesignet i avsnitt 6.4.

Tabell 5: Diebold-Mariano-tester

Sammenligningspar	DM-statistikk	p-verdi	Konklusjon
Holt-Winters vs. ARIMA	1,766	0,078	Ikke signifikant ($p > 0,05$)
XGBoost vs. ARIMA	-0,779	0,436	Ikke signifikant ($p > 0,05$)

8.0 Diskusjon

Dette kapittelet diskuterer resultatene fra analysen opp mot problemstillingen, eksisterende litteratur og praktiske implikasjoner for logistikkplanlegging. Der resultatene avviker fra forventningene, drøftes mulige forklaringer.

8.1 Svar på problemstillingen

Studiens problemstilling er:

Hvilke prognosemodeller egner seg best for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system, og i hvilken grad varierer modellprestasjonene på tvers av produktsegmenter?

Resultatene viser at XGBoost global har lavest observert median MAPE på tvers av de 105 varelinjene (52,19 %), etterfulgt av ARIMA (57,77 %), Holt-Winters (62,49 %) og naiv prognose (67,50 %). XGBoost global har lavest observert prognosefeil på alle tre feilmål — RMSE (811,24), MAE (702,95) og MAPE (52,19 %) — men forskjellen mot ARIMA er ikke statistisk signifikant ($DM = -0,779$, $p = 0,436$). Alle modeller forbedrer seg konsistent over den naive referanseprognosen (67,50 %).

Svaret på problemstillingen er at XGBoost global gir lavest prognosefeil under de betingelsene som er analysert. Et kontrollleksperiment med XGBoost trent individuelt per SKU — med de samme 36 treningsobservasjonene som Holt-Winters og ARIMA — gir MAPE 62,61 %, nesten identisk med Holt-Winters (62,49 %) og klart svakere enn global XGBoost. Dette bekrefter at global pooling er den primære kilden til XGBoosts fordel, ikke gradient boosting-arkitekturen alene. Funnet diskuteres videre i avsnitt 8.3.

De tre underspørsmålene kan oppsummeres som følger:

RQ1 besvares bekreftende: XGBoost global gir lavest prognosefeil på samtlige tre feilmål — RMSE (811,24), MAE (702,95) og MAPE (52,19 %) — i testperioden, selv om absoluttnivåene er høye. ARIMA (MAPE 57,77 %) og Holt-Winters (MAPE 62,49 %) presterer begge klart bedre enn den naive referansen (MAPE 67,50 %).

RQ2 besvares bekreftende: Den relative modellprestasjonen varierer tydelig mellom segmenter. XGBoost er klart best for høyvolumsegmentet (MAPE 49,46 %) og for SKU-er uten tydelig sesongmønster (MAPE 51,50 %), men er svakest for SKU-er med tydelig sesongmønster (MAPE 79,13 %), der ARIMA (69,86 %) og Holt-Winters (65,82 %) er mer robuste.

RQ3 besvares med forbehold: XGBoost gir en observert forbedring på 10,3 prosentpoeng i MAPE over Holt-Winters, men DM-testen mellom XGBoost og ARIMA viser ingen statistisk signifikant forskjell ($DM = -0,779$, $p = 0,436$). DM-testen mellom Holt-Winters og ARIMA er heller ikke signifikant ($DM = 1,766$, $p = 0,078$). Den observerte rangordningen bør tolkes som en indikasjon, ikke en sikker konklusjon.

8.2 Sammenligning med litteraturen

Resultatene støtter eksisterende forskning på feltet.

Fourkiotis og Tsadiras (2024) finner at XGBoost typisk gir lavere prognosefeil enn tradisjonelle statistiske modeller på farmasøytiske salgsdata. Dette er konsistent med funnene i denne studien, der XGBoost gir en MAPE-forbedring på 15,53 prosentpoeng sammenlignet med den naive prognosen og 10,52 prosentpoeng over Holt-Winters. Forbedringen er imidlertid moderat, og de klassiske modellene (Holt-Winters og ARIMA) presterer fortsatt vesentlig bedre enn referansenivået.

Burinskiene (2020) påpeker at datakvalitet og struktureringsnivå er like viktig som modellvalg. Dette er relevant for forståelsen av hvorfor Holt-Winters og ARIMA yter relativt godt på dette datasettet: leveransedataene fra et sentrallager-grossist-system har en relativt stabil struktur med begrenset støy, noe som favoriserer klassiske tidsseriemodeller.

Absoluttnivåene for MAPE (52–68 %) er høye sammenlignet med hva som rapporteres for forbruksvarer med stabil etterspørsel, men er i tråd med Burinskiene (2020), som rapporterer tilsvarende nivåer for farmasøytiske data kjennetegnet av høy etterspørselsvariabilitet og et høyt innslag av lavvolum-produkter. I dette perspektivet bør modellsammenligningen primært tolkes relativt — rangordningen mellom modellene er den sentrale konklusjonen, ikke absoluttverdiene.

Zhu et al. (2021) demonstrerer at maskinlæringsmodeller som kombinerer historiske salgsdata med forsyningskjedeinformasjon gir signifikante forbedringer i prognosepresisjon for farmasøytiske produkter. XGBoost i denne studien benytter kun historiske leveranseverdier uten eksogene variabler som bestillingsdata, kampanjekalendere eller epidemiologiske indikatorer. Funnene kan dermed tolkes som en konservativ nedre grense for hva maskinlæringsmetoder kan oppnå på dette datasettet — tilgang på rikere forsyningskjededata ville trolig ha styrket XGBoosts relative fordel ytterligere.

Hyndman og Athanasopoulos (2021) og Petropoulos et al. (2022) argumenterer for at enkle modeller ofte presterer like godt som komplekse modeller på korte tidsserier. Studiens resultater utfordrer delvis dette synet — XGBoost gir konsistent lavere feilmål — men bekrefter samtidig at forskjellene er relativt moderate, og at Holt-Winters gir akseptabel prognosepresisjon med langt lavere implementeringskompleksitet.

Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA ($DM = 1,766$, $p = 0,078$). Dette indikerer at de to klassiske metodene er likeverdige i presisjonsevne på dette datasettet, til tross for at ARIMA gir noe lavere RMSE og MAPE i gjennomsnitt.

DM-testen mellom XGBoost og ARIMA viser heller ingen statistisk signifikant forskjell ($DM = -0,779$, $p = 0,436$). Til tross for at XGBoost har en observert MAPE-fordel på 5,6 prosentpoeng over ARIMA, er denne forskjellen ikke statistisk etterprøvbart på dette datasettet. Samlet sett gir DM-testene ikke grunnlag for å konkludere med at noen av de tre modellene er systematisk overlegne hverandre utover tilfeldig variasjon — den rangordningen som fremgår av medianverdiene i Tabell 2, bør tolkes som en indikasjon snarere enn en sikker konklusjon.

8.3 Modellkompleksitet og praktisk nytte

Et sentralt spørsmål i litteraturen er om økt modellkompleksitet gir reell merverdi i operativ planlegging. Resultatene i denne studien viser at XGBoost gir best prognosepresisjon, men forbedringen over Holt-Winters på MAPE er på om lag 10,5 prosentpoeng. Spørsmålet er om denne gevinsten forsvarer den økte implementeringskompleksiteten.

En sentral metodisk presisering er at den globale XGBoost-modellen og de individuelle statistiske modellene opererer på fundamentalt ulike treningsgrunnlag: global XGBoost trenes på 3 780 observasjoner (105 SKU-er $\times$ 36 måneder), mens Holt-Winters og ARIMA tilpasses individuelt på 36 observasjoner per modell. For å isolere effekten av modellarkitektur fra effekten av global datautnyttelse ble XGBoost i denne studien også trent individuelt per SKU — 105 separate modeller, hver med de samme 36 treningsobservasjonene som Holt-Winters og ARIMA. Med lag 1–12 gir dette kun ~24 brukbare treningsrader per modell.

Resultatet er entydig: XGBoost individuell oppnår median MAPE 62,61 %, nesten identisk med Holt-Winters (62,49 %) og klart svakere enn global XGBoost (52,19 %). Gradient boosting-arkitekturen alene forklarer dermed ikke XGBoosts fordel. Det som skiller global XGBoost fra de øvrige metodene, er muligheten til å låne mønstre på tvers av produktporteføljen — den økte datautnyttelsen fra pooling, ikke algoritmen som sådan. Bidraget fra dette kontrolleksperimentet er å demonstrere at global maskinlæring *som pakke* — inkludert den økte datautnyttelsen — gir observert bedre presisjon, og at pooling-effekten er en reell og kvantifiserbar komponent av XGBoosts relative fordel på dette datasettet.

For virksomheter med tilgjengelig datakompetanse og Python-infrastruktur kan XGBoost vurderes, særlig dersom porteføljen er bred nok til å utnytte pooling-effekten. For virksomheter med begrensede analytiske ressurser vil Holt-Winters gi tilfredsstillende prognoser med langt lavere krav til vedlikehold og tolkning. Dette er særlig relevant i farmasøytisk distribusjon, hvor leveringspålitelighet og forutsigbarhet veier tyngre enn marginal presisjonsgevinst.

Videre er det verdt å merke seg at ARIMA ikke gir signifikant bedre prognoser enn Holt-Winters ($DM = 1,766$, $p = 0,078$), noe som taler mot den ekstra modelltilpasningskostnaden ARIMA krever

i form av parametervalg og stasjonaritetstesting.

8.4 Metodiske begrensninger

Studien har flere begrensninger som bør tas i betraktning ved tolkning av resultatene:

Leveranser som proxy for etterspørsel: Datasettet representerer leveranser fra sentrallager til grossister, ikke sluttkundesalg. Bullwhip-effekter kan medføre at modellene fanger opp variasjoner i bestillingsatferd snarere enn reell sluttetterspørsel.

Kort historikk for XGBoost: Med 36 måneder treningsdata per varelinje er datagrunnlaget relativt begrenset for en maskinlæringsmodell. XGBoost er generelt best egnet for større datasett, og resultatene kan derfor ikke uten videre generaliseres til situasjoner med lengre historikk. Med mer data ville XGBoost potensielt gitt enda større fordel over de klassiske modellene.

Pooling-effekt kvantifisert: Holt-Winters og ARIMA er modellert individuelt per varelinje, mens XGBoost er trent som en global modell på alle 105 SKU-er. Et kontrollleksperiment der XGBoost ble trent individuelt per SKU viser MAPE 62,61 % — nesten identisk med Holt-Winters (62,49 %) og klart svakere enn global XGBoost (52,19 %). Asymmetrien er dermed ikke bare en begrensning, men et kvantifisert funn: global pooling er den primære kilden til XGBoosts fordel.

Ekstern validitet: Resultatene gjelder ett distribusjonsselskap i én bransje. Overførbarheten til andre bransjer eller distribusjonssystemer er begrenset.

8.5 Implikasjoner for næringslivet

For virksomheter i farmasøytisk distribusjon med tilsvarende datastruktur gir studien følgende praktiske implikasjoner:

- **XGBoost (global)** kan vurderes der datakompetanse og Python-infrastruktur er tilgjengelig, og der virksomheten har mange SKU-er som kan utnytte pooling-effekten. Det understrekes at fordelene over ARIMA ikke er statistisk signifikant på dette datasettet, og at XGBoost bør testes opp mot egne data før implementering.
- **Holt-Winters** anbefales som standardmodell for virksomheter uten avansert analysekapasitet — modellen gir akseptabel presisjon, er lett å implementere og vedlikeholde, og presterer stabilt på tvers av segmenter.
- **For SKU-er med tydelig sesongmønster** bør Holt-Winters eller ARIMA vurderes fremfor global XGBoost, da XGBoost presterer svakest i dette segmentet (MAPE 79,13 % versus Holt-Winters 65,82 %).
- Det er ikke grunnlag for å foretrekke ARIMA over Holt-Winters på dette datasettet, gitt at Diebold-Mariano-testen ikke viser signifikant forskjell og ARIMA krever mer kompleks modelltilpasning.

- For varelinjer med lavt volum eller uregelmessig etterspørsel bør prognosene suppleres med manuell vurdering, da alle modeller viser høyere prognosefeil i denne gruppen.

9.0 Konklusjon

Studien sammenlignet fem prognosemodeller på et anonymisert datasett med 105 farmasøytiske varelinjer over 48 måneder (treningssett 2022–2024, testperiode januar–desember 2025).

RQ1: XGBoost global har lavest observert prognosefeil på alle tre feilmål — RMSE (811,24), MAE (702,95) og MAPE (52,19 %) — men forskjellen mot ARIMA er ikke statistisk signifikant (DM = -0,779, $p = 0,436$). Alle modeller forbedrer seg over den naive referansen (MAPE 67,50 %).

RQ2: Modellprestasjonene varierer tydelig mellom segmenter. XGBoost er sterkest for høyvolumsegmentet (MAPE 49,46 %) og ikke-sesongpregede SKU-er (MAPE 51,50 %), men svakest for SKU-er med tydelig sesongmønster (MAPE 79,13 %), der Holt-Winters (65,82 %) og ARIMA (69,86 %) er mer robuste.

RQ3: Ingen av de testede modellparene skiller seg statistisk signifikant fra hverandre i DM-test. Økt modellkompleksitet gir observert, men ikke signifikant bekreftet, merverdi på dette datasettet.

Et kontrolleksperiment der XGBoost ble trent individuelt per SKU (MAPE 62,61 %) — med de samme 36 treningsobservasjonene som Holt-Winters og ARIMA — bekrefter at global pooling er den primære årsaken til XGBoosts fordel, ikke gradient boosting-arkitekturen alene.

Hovedkonklusjonen er ikke at XGBoost alltid er best, men at global datadeling på tvers av SKU-er kan gi merverdi når hver enkelt tidsserie er kort. Samtidig viser manglende statistisk signifikans at praktisk modellvalg bør baseres på en kombinasjon av prognosepresisjon, implementeringskompleksitet og organisatorisk gjennomførbarhet — der Holt-Winters fremstår som et robust og lavterskel-alternativ for virksomheter uten avansert analysekapasitet.

9.1 Videre forskning

Denne studien reiser flere spørsmål som kan være utgangspunkt for videre forskning:

- **Lengre historikk:** En tilsvarende studie med lengre tidsserier (f.eks. 72–96 måneder) ville gi et bedre grunnlag for å vurdere XGBoosts potensial som global prognosemodell.
- **Hierarkisk prognosering:** Fremtidige studier kan undersøke om prognoser på aggregert nivå (f.eks. terapeutisk kategori) gir bedre presisjon enn prognoser per varelinje.
- **Hybrid-modeller:** Kombinasjoner av klassiske og maskinlæringsbaserte metoder er et voksende forskningsfelt som kan gi bedre resultater enn enkeltstående modeller.
- **Eksogene variabler:** Inkludering av eksterne faktorer som sesonginfluensa, legemiddelmangel eller regulatoriske endringer kan forbedre prognosenøyaktigheten for utvalgte produktkategorier.

- **Global versus individuell pooling for andre modeller:** Kontrolleksperimentet i denne studien bekrefter at global pooling er den primære årsaken til XGBoosts fordel. Et naturlig neste steg er å undersøke om globale varianter av Holt-Winters eller ARIMA (f.eks. hierarkisk prognosering eller vektorautoregresjon) gir tilsvarende gevinst — dette ville gjøre det mulig å sammenligne modellarkitekturer direkte uten confounding fra ulike treningsdatamengde.
- **AI som forskningsmetode:** Fremtidige studier kan undersøke hvordan AI-verktøy påvirker kvalitet, effektivitet og forskerens kontroll i kvantitative forskningsprosjekter — herunder i hvilken grad human-in-the-loop-tilnærminger sikrer metodisk integritet og reproduserbarhet i analysearbeid.

10.0 Bibliografi

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.

Bryman, A. (2012). *Social research methods* (4th ed.). Oxford University Press.

Burinskiene, A. (2020). Forecasting model: The case of the pharmaceutical retail. *Frontiers in Medicine*, 7, 582186. <https://doi.org/10.3389/fmed.2020.582186>

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. <https://doi.org/10.1145/2939672.2939785>.

Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on Loess. *Journal of Official Statistics*, 6(1), 3–73.

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>.

Fourkiotis, K. P., & Tsadiras, A. K. (2024). Applying machine learning and statistical forecasting methods for enhancing pharmaceutical sales predictions. *Forecasting*, 6(1), 170–186. <https://doi.org/10.3390/forecast6010010>

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>

Lee, H. L., Padmanabhan, V., & Whang, S. (1997). The bullwhip effect in supply chains. *Sloan Management Review*, 38(3), 93–102.

Lov om apotek [apotekloven], LOV-2000-06-02-39. (2000). Lovdata.
<https://lovdata.no/dokument/NL/lov/2000-06-02-39>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364.
<https://doi.org/10.1016/j.ijforecast.2021.11.013>

Petropoulos, F., Spiliotis, E., & Assimakopoulos, V. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871.
<https://doi.org/10.1016/j.ijforecast.2021.11.001>

Said, S. E., & Dickey, D. A. (1984). Testing for unit roots in autoregressive-moving average models of unknown order. *Biometrika*, 71(3), 599–607. <https://doi.org/10.1093/biomet/71.3.599>

Statens legemiddelverk. (2024). Årsrapport 2023.
<https://www.regjeringen.no/contentassets/d68bf504a21a4645b3c04ef31697fd6c/slv-arsrapport-2023.pdf>

Zhu, X., Ninh, A., Zhao, H., & Liu, Z. (2021). Demand forecasting with supply chain information and machine learning: Evidence in the pharmaceutical industry. *Production and Operations Management*, 30(10), 3231–3252. <https://doi.org/10.1111/poms.13458>

Vedlegg

Vedlegg A: Samlede prognoseresultater

Tabellen nedenfor viser medianverdiene for RMSE, MAE og MAPE på tvers av alle 105 varelinjer i testperioden (januar–desember 2025). Resultatene er hentet direkte fra analysekoden og er grunnlaget for Tabell 2 i kapittel 8.2.

Modell	RMSE (median)	MAE (median)	MAPE (median, %)	SKU-er
Naiv (sesongnaiv)	1131,65	914,58	67,50	105
Holt-Winters	935,84	769,90	62,49	105
XGBoost (individuell)	949,67	845,80	62,61	105
ARIMA / SARIMA	846,20	820,01	57,77	105
XGBoost (global)	811,24	702,95	52,19	105

Kilde: `resultater_sammenligning.csv` generert av `analyse.py`.

Vedlegg B: Reproduserbarhet og kode

Analysen er gjennomført i Python (versjon 3.11) med følgende biblioteker:

Bibliotek	Versjon	Formål
pandas	2.x	Databehandling og strukturering
numpy	1.x	Numeriske beregninger
statsmodels	0.14.x	Holt-Winters og stasjonaritetstesting
pmdarima	2.x	Automatisk ARIMA-parametervalg
xgboost	2.x	XGBoost-modellering
matplotlib	3.x	Visualisering
scikit-learn	1.x	Evalueringsmetrikker og krysskalibrering

All kode er versjonskontrollert i prosjektets Git-repository og kan gjengis ved å kjøre `analyse.py` med datasettet `salgsdata_anonymized.csv`. Random seed er satt til 42 og train/test-split er 36/12 måneder for alle kjøringene.

Vedlegg C: Datasettbeskrivelse

Datasettet `salgsdata_anonymized.csv` inneholder følgende struktur:

Kolonne	Beskrivelse
sku_id	Anonymisert produktidentifikator
year_month	År og måned (format: YYYY-MM)
quantity	Månedlig leveransevolum (pakninger)

Datasettet er anonymisert og kan ikke gjøres offentlig tilgjengelig. Tilsvarende analyser kan gjennomføres på datasett med identisk struktur.

Vedlegg D: XGBoost global versus XGBoost individuell — pooling-effekten forklart

D.1 Bakgrunn og formål

XGBoost ble i denne studien implementert på to fundamentalt ulike måter: som én global modell trent på alle 105 SKU-er samlet (*global pooling*), og som 105 separate modeller trent individuelt per SKU. Begge varianter bruker identiske featurevektorer, identiske hyperparametere og identisk evalueringsrammeverk. Den eneste systematiske forskjellen er mengden treningsdata modellen har tilgang til. Formålet med dette vedlegget er å tydeliggjøre hva denne forskjellen innebærer metodisk, og å dokumentere den kvantifiserte effekten på prognosepresisjon.

D.2 To fundamentalt ulike treningsstrategier

Tabellen nedenfor sammenligner treningsbetingelsene for de to XGBoost-variantene.

Tabell D.1: Treningsbetingelser — XGBoost global versus XGBoost individuell

Betingelse	XGBoost global	XGBoost individuell
Antall modeller	1	105
Treningsstrategi	Alle 105 SKU-er poolet	Én separat modell per SKU
Treningsobservasjoner totalt	3 780 (105×36 mnd)	36 per modell
Brukbare treningsrader etter lag 1–12	$\sim 2\,520$ (105×24)	~ 24 per modell
Featurevektorer	Identiske	Identiske
Hyperparametere	Identiske ($n=300$, $lr=0,05$, $depth=4$)	Identiske
Kan lære mønstre på tvers av SKU-er	Ja	Nei
Risiko for overfit på enkelt-SKU	Lav	Høy

Den kritiske forskjellen ligger i fjerde rad: den globale modellen har tilgang til $\sim 2\,520$ brukbare treningsrader fra hele porteføljen, mens hver individuell modell kun har ~ 24 treningsrader til rådighet etter at lagstrukturen er etablert. For en trebasert ensemblemetode som XGBoost — som i utgangspunktet er designet for store datasett — er 24 observasjoner et svært begrenset grunnlag.

D.3 Hvorfor global trening er viktig for trebaserte modeller

Gradient boosting-metoder som XGBoost lærer komplekse, ikke-lineære mønstre ved å bygge mange beslutningstrær sekvensielt. Effektiviteten til denne tilnærmingen avhenger kritisk av at det finnes tilstrekkelig med treningsdata til å estimere stabile splittepunkter i hvert tre. Med kun ~24 treningsrader per individuell modell oppstår to problemer:


Datamangel og overfitting: Et beslutningstre med `max_depth = 4` kan i prinsippet representere $2^4 = 16$ bladnoder. Med 24 treningsrader gir dette svært få observasjoner per bladnode. Selv med regularisering (λ -straff på bladvekter) er dette et grunnleggende problem: modellen har for lite data til å skille reelle mønstre fra støy, og risikerer å memorere treningssettet fremfor å generalisere til testperioden.

Manglende tverrproduktlæring: Mange av de 105 SKU-ene deler strukturelle likhetstrekk — sesongmønstre, trendretning og reaksjoner på tidspunkter som kvartalsslutt eller vinterhalvår. Den globale modellen kan lære disse delte mønstrene fra hele porteføljen og anvende dem på alle SKU-er, inkludert produkter der det individuelle datamaterialet er sparsomt. Den individuelle modellen er blind for denne informasjonen og må estimere alle mønstre fra egne 24 observasjoner alene.

Pooling som informasjonsdeling: I prognosesammenheng er global pooling beslektet med hierarkisk prognosering og cross-learning — prinsipper som har vist sterk empirisk støtte i M5-konkurransen (Makridakis et al., 2022), der de best plasserte løsningene nettopp utnyttet mønstre på tvers av produkter fremfor å modellere hvert produkt isolert.

D.4 Kvantifisering av pooling-effekten

Figur D.1 illustrerer treningsstrategiene og prestasjonsforskjellen visuelt. Panel A viser skjematisk at individuell trening gir 105 separate modeller med ~24 treningsrader hver, mens global trening pooler all data til én modell med ~2 520 treningsrader. Panel B viser median MAPE for alle fem modeller med pooling-effekten annotert.



Figur D.1: XGBoost global versus XGBoost individuell — treningsstrategi og pooling-effekt

Tabell D.2 sammenligner prestasjonene for de to XGBoost-variantene direkte opp mot hverandre og mot de øvrige modellene i studien.

Tabell D.2: Prestasjonssammenligning — XGBoost global og XGBoost individuell (median over 105 SKU-er, testperiode Jan–Des 2025)

Modell	RMSE	MAE	MAPE (%)	Relativ MAPE vs. XGB global
Naiv (sesongnaiv)	1 131,65	914,58	67,50	+15,31 pp
Holt- Winters	935,84	769,90	62,49	+10,30 pp
XGBoost individuell	949,67	845,80	62,61	+10,42 pp
ARIMA / SARIMA	846,20	820,01	57,77	+5,58 pp
XGBoost global	811,24	702,95	52,19	—

pp = prosentpoeng

Tre observasjoner er sentrale ved lesing av tabellen:

- XGBoost individuell presterer tilnærmet identisk med Holt-Winters** (MAPE 62,61 % versus 62,49 %). En statistisk modell spesialbygd for sesongvariasjon og en generell maskinlæringsmodell med 24 treningsrader per SKU gir altså nesten nøyaktig samme resultat. Dette bekrefter at gradient boosting-arkitekturen i seg selv ikke gir noen fordel når datagrunnlaget er tilsvarende.
- Gapet mellom XGBoost individuell og XGBoost global er 10,42 prosentpoeng i MAPE**, et like stort gap som mellom naiv prognose og Holt-Winters. Den eneste variabelen som skiller de to XGBoost-variantene er tilgangen til poolen treningsdata — og effekten er substansiell.
- XGBoost global oppnår lavere RMSE og MAE enn alle øvrige modeller**, men den relative forbedringen er størst i RMSE (17,1 % lavere enn XGBoost individuell) og MAE (20,3 % lavere). Dette indikerer at den globale modellen i særlig grad reduserer de store prognoseavvikene som RMSE er sensitiv for.

D.5 Konklusjon

Kontrolleksperimentet med XGBoost individuell isolerer pooling-effekten og viser at den er den primære årsaken til XGBoost globals relative overlegenhet i denne studien. Gradient boosting-algoritmen alene — uten tilgang til porteføljens samlede historikk — gir ikke bedre prognoser enn Holt-Winters på et datasett med 36 måneder per SKU. Global trening er dermed ikke bare en teknisk implementasjonsdetalj, men en forutsetning for at XGBoost skal gi reell merverdi i kontekster med kort dataserier og mange produktlinjer. For praktikere innebærer dette at effekten av XGBoost er betinget av at virksomheten har en tilstrekkelig bred produktportefølje med felles historikk å trene på — et poeng som er like relevant som valget av algoritme.