LOG650 – Etterspørselsprognoser – Morten Eidsvåg

-
- 1.0 Innledning
  - Problemstilling
  - Avgrensinger
  - Antagelser
- Litteratur
- Teori
- Casebeskrivelse
- Metode
- Data
- Modellering
  - 6.1 Modelleringsrammeverk
  - 6.2 Evaluering
  - 6.3 Naiv prognose (referansemodell)
  - 6.4 Holt-Winters eksponentiell glatting
  - 6.5 ARIMA
  - 6.6 XGBoost
- Analyse
  - 7.1 Utforskende dataanalyse
  - 7.2 Evalueringsdesign
  - 7.3 Klassifisering av tidsserier
  - 7.4 Statistisk sammenligning
- Resultat
  - 8.1 Utforskende dataanalyse
  - 8.2 Prognosepresisjon — samlede resultater
  - 8.3 Resultater per undergruppe
  - 8.4 Statistisk test

- Diskusjon
  - 9.1 Svar på problemstillingen
  - 9.2 Sammenligning med litteraturen
  - 9.3 Modellkompleksitet og praktisk nytte
  - 9.4 Metodiske begrensninger
  - 9.5 Implikasjoner for næringslivet
- Konklusjon
  - 10.1 Videre forskning
- Bibliografi
- Vedlegg

Abstract

Student: Morten Eidsvåg | **Emne:** LOG650 Forskningsprosjekt | **Arbeidsform:** Individuelt

Denne studien undersøker hvilken prognosemodell som gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system. Fire modeller sammenlignes på et anonymisert datasett bestående av 105 SKU-er over 48 måneder (januar 2022 – desember 2025): naiv sesongprognose, Holt-Winters eksponentiell glatting, ARIMA/SARIMA og XGBoost. Modellene trenes på de første 36 månedene og evalueres på de siste 12 månedene ved hjelp av feilmålene RMSE, MAE og MAPE (median over alle SKU-er).

Resultatene viser at XGBoost gir lavest prognosefeil på alle tre feilmål (MAPE: 51,97 %; RMSE: 757,23; MAE: 654,94), etterfulgt av ARIMA (MAPE: 57,77 %), Holt-Winters (MAPE: 62,49 %) og naiv prognose (MAPE: 67,50 %). Alle modeller forbedrer seg over referansenivået. Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA (DM = 1,508, p = 0,132). Segmentert analyse viser at XGBoost er særlig overlegen for SKU-er uten tydelig sesongmønster og for varelinjer med høyt volum, men presterer svakt på lavvolum-SKU-er (MAPE: 82,33 %).

Studien konkluderer med at XGBoost gir best prognosepresisjon som global modell, men at Holt-Winters er et robust og praktisk alternativ der avansert analysekapasitet ikke er tilgjengelig. Det er ikke grunnlag for å foretrekke ARIMA over Holt-Winters på dette datasettet.

Innhold

1.0 Innledning [1](#innledning)

1.1 Problemstilling [2](#problemstilling)

1.2 Delproblemer (valgfri) [2](#_Toc222057405)

1.3 Avgrensinger [2](#avgrensinger)

1.4 Antagelser [3](#antagelser)

2.0 Litteratur [3](#litteratur)

3.0 Teori [3](#teori)

4.0 Casebeskrivelse [4](#casebeskrivelse)

5.0 Metode og data [4](#_Toc222057411)

5.1 Metode [4](#metode-vent-med-denne)

5.2 Data [5](#data)

6.0 Modellering [6](#modellering)

7.0 Analyse [6](#_Toc222057415)

8.0 Resultat [6](#_Toc222057416)

9.0 Diskusjon [7](#_Toc222057417)

10.0 Konklusjon [8](#_Toc222057418)

11.0 Bibliografi [8](#bibliografi)

Vedlegg [8](#vedlegg)

1.0 Innledning

Etterspørselsprognoser er sentrale i beslutningsprosessene innen logistikk og supply chain management. Prognoser danner grunnlaget for planlegging av produksjon, lagerbeholdning og distribusjon i forsyningskjeder (Hyndman & Athanasopoulos, 2021). Den farmasøytiske sektoren kjennetegnes av sesongvariasjoner, regulatoriske krav og høye krav til leveringspålitelighet. I Norge har man gjennom flere tiår bygget ned nasjonale beredskapslagre for legemidler. Tidligere hadde staten et mer direkte

ansvar for beredskapslager gjennom Norsk Medisinaldepot (NMD). Etter innføringen av apotekloven 1. mars 2001 så ble dette i noen grad erstattet med minstekrav til leveringsgrad for legemidler (Lov om apotek §5-4).

Til tross for dette har Norge opplevd flere tilfeller av legemiddelmangel de senere årene. Slike mangelsituasjoner kan skyldes både globale forsyningsproblemer og mangelfulle etterspørselsprognoser. Feilprognoser kan føre til enten legemiddelmangel, med potensielle helsemessige konsekvenser, eller overlagring som gir økte kostnader og risiko for tapt salg.

Tradisjonelt har etterspørselsprognoser vært basert på statistiske tidsseriemodeller som eksponentiell glatting og ARIMA (Hyndman & Athanasopoulos, 2021). Eksponentiell glatting, inkludert Holt–Winters-metoden, er spesielt utviklet for tidsserier som inneholder både trend og sesongmønstre, og er derfor mye brukt i operativ etterspørselsplanlegging (Hyndman & Athanasopoulos, 2021). Innen farmasøytisk industri viser studier at Holt–Winters ofte gir tilfredsstillende prognosenøyaktighet når dataserier inneholder tydelige sesongkomponenter (Burinskiene, 2022).

Nyere forskning indikerer imidlertid at maskinlæringsmetoder kan håndtere mer komplekse og ikke-lineære mønstre i data. Spesielt har gradient boosting-metoder som XGBoost vist gode resultater i prognoseoppgaver hvor tradisjonelle modeller ikke fanger opp komplekse sammenhenger (Chen & Guestrin, 2016; Fourkiotis & Tsadiras, 2024).

Litteraturgjennomgangen viser derfor et metodisk spenn mellom klassiske statistiske modeller og nyere maskinlæringsmetoder. Samtidig er det fortsatt uklart i hvilken grad mer komplekse AI-modeller faktisk gir merverdi i situasjoner med begrenset historikk og panelstruktur på produktnivå, slik mange distribusjonsbedrifter opererer med i praksis.

Denne rapporten undersøker derfor hvordan ulike prognosemodeller presterer på reelle distribusjonsdata fra et sentrallager til grossister, bestående av 105 varelinjer over en periode på 48 måneder. Studien søker å bidra med innsikt i hvilken modelltype som gir best balanse mellom prognosepresisjon, robusthet og operasjonell anvendbarhet i logistikkplanlegging.

Problemstilling

Med utgangspunkt i ovenstående aktualisering formuleres følgende problemstilling:

Hvilken prognosemodell gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system, gitt et datasett på 48 måneder og 105 produkter?

For å besvare problemstillingen sammenlignes tre prognosemodeller:

> *Holt–Winters eksponentiell glatting*
>
> *ARIMA*
>
> *XGBoost*

Modellene evalueres ved hjelp av etablerte prognosenøyaktighetsmål som **RMSE, MAE og MAPE**, som er blant de mest brukte målene for å evaluere prognosemodeller i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Analysen søker ikke bare å identifisere hvilken modell som gir best prognosepresisjon, men også å diskutere hvorvidt økt modellkompleksitet gir reell merverdi i et praktisk planleggingsperspektiv.

Avgrensinger

Oppgavens natur og tilgang på data gjør det nødvendig at det For å sikre analytisk presisjon gjøres følgende avgrensninger:

Datasett: Studien benytter kun historiske leveransedata (månedlig volum). Eksterne forklaringsvariabler som pris, kampanjer, demografi eller regulatoriske utfordringer inkluderes ikke.

Tidsperiode: Datasettet dekker totalt 48 måneder (januar 2022 – desember 2025), hvorav 36 måneder benyttes som treningssett og 12 måneder som testsett. Lengre historikk er ikke tilgjengelig og vurderes derfor ikke.

Horisont: Fokus er på kort- til mellomlangsiktig prognose relevant for lager- og produksjonsplanlegging.

Modellutvalg: Kun utvalgte representative modeller innen klassisk og nyere tidsserieanalyse er vurdert i denne oppgaven.

Struktur: Prognoser utvikles på varelinjenivå.

Disse avgrensningene gjør det mulig å analysere modellenes prestasjon under realistiske betingelser, samtidig som metodisk nøyaktighet opprettholdes.

Antagelser

For å sikre at analysen blir pålitelig må det gjøres følgende antagelser om dataene og metodene som analyseres. Antagelsene tydeliggjør forutsetningene som ligger i modellene og avgrenser samtidig

tolkningen av resultatene. I tidsserieanalyse er slike forutsetninger nødvendige fordi prognosemodeller bygger på at historiske observasjoner inneholder informasjon som kan brukes til å predikere fremtidige verdier (Hyndman & Athanasopoulos, 2021).

Antagelse 1: Leveranser reflekterer virkelig etterspørsel

Det antas at månedlige leveranser fra sentrallager til grossister i hovedsak reflekterer faktisk etterspørsel, og at leveransene ikke systematisk påvirkes av hamstring, kampanjer eller regulatoriske forhold. Siden analysen baseres på leveranser til grossister og ikke sluttkundesalg, kan bullwhip-effekter føre til at variasjoner i etterspørselen forsterkes gjennom distribusjonsleddene. Dette kan innebære at modellene i noen tilfeller fanger opp variasjoner i bestillingsatferd snarere enn reell sluttkundedemand.

Antagelse 2: Stabile data i tid

Trend- og sesongkomponenter antas å være relativt stabile i treningsperioden på 36 måneder. Både klassiske tidsseriemodeller som Holt–Winters og ARIMA bygger på antagelsen om at historiske mønstre i dataene inneholder informasjon om fremtidige observasjoner (Hyndman & Athanasopoulos, 2021). Dersom dataserien inneholder strukturelle brudd eller større regimeendringer, kan dette redusere modellens prognoseevne.

Antagelse 3: Uavhengige varelinjer

Hver varelinje modelleres uavhengig av øvrige produkter. Krysselastisiteter og substitusjonseffekter mellom produkter inngår derfor ikke eksplisitt i analysen. Dette innebærer at hver tidsserie analyseres separat, noe som er vanlig praksis i klassisk tidsserieprognostisering når produktene har egne etterspørselsmønstre (Hyndman & Athanasopoulos, 2021).

Antagelse 4: Eksterne faktorer reflekteres i historikken

Effekter av prisendringer, kampanjer eller regulatoriske forhold antas å være implisitt representert i de historiske observasjonene. Dette er en nødvendig antagelse ettersom modellene som benyttes i studien primært er basert på univariate tidsserier uten eksterne forklaringsvariabler.

Antagelse 5: Ingen systematiske prognosefeil

Det antas at avvikene i modellene ikke inneholder vedvarende systematisk over- eller underestimering. En slik antagelse er nødvendig for at prognosemål som RMSE, MAE og MAPE skal gi en meningsfull sammenligning av modellene, ettersom disse målene brukes til å evaluere prognosepresisjon i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Samlet konsekvens

Antagelsene innebærer at studiens resultater primært gjelder stabile distribusjonssystemer uten større strukturelle brudd. Dersom markedet påvirkes av betydelige eksterne endringer eller uforutsigbare hendelser, kan modellens prognosenøyaktighet bli redusert.

Litteratur

Etterspørselsprognoser er et sentralt forskningsområde innen logistikk og supply chain management, ettersom prognosenøyaktighet påvirker beslutninger knyttet til lagerstyring, produksjonsplanlegging og distribusjon. I farmasøytisk sektor er dette særlig viktig, ettersom feilprognoser kan føre til både legemiddelmangel og økt kapitalbinding i lager. De siste årene har forskningen i økende grad fokusert på sammenligning mellom tradisjonelle tidsseriemodeller og nyere maskinlæringsmetoder, med mål om å forbedre prognosenøyaktigheten i komplekse etterspørselssystemer.

Tradisjonelle statistiske modeller, særlig eksponentiell glatting og ARIMA-modeller, har lenge vært standardmetoder for operativ etterspørselsplanlegging. Disse metodene er godt etablert i litteraturen og er kjent for å være relativt robuste når dataserier viser stabile trend- og sesongmønstre (Hyndman & Athanasopoulos, 2018). Holt–Winters-metoden, som er en videreføring av eksponentiell glatting, er spesielt utviklet for tidsserier med både trend og sesongkomponenter og brukes derfor ofte i praktisk salgs- og lagerprognostisering.

Innen farmasøytisk retail viser Burinskiene (2022) at prognosenøyaktighet ikke bare påvirkes av valg av modell, men også av hvordan dataene struktureres og behandles. Studien analyserer prognoser for legemiddelprodukter på apoteknivå og viser at prognoser utviklet på et mer detaljert nivå kan gi bedre presisjon enn prognoser basert på mer aggregerte data. Studien fremhever også betydningen av datakvalitet, blant annet gjennom håndtering av outliers og perioder med mangel på varer. Disse funnene indikerer at kvaliteten på datagrunnlaget og nivået prognosen utvikles på kan være like viktig som selve modellvalget.

Parallelt med denne forskningen har det de siste årene vært økende interesse for maskinlæringsbaserte metoder innen etterspørselsprognoser. Slike metoder har potensial til å fange mer komplekse og ikke-lineære sammenhenger i data enn tradisjonelle statistiske modeller. Fourkiotis og Tsadiras (2024) sammenligner flere statistiske modeller og maskinlæringsmetoder på farmasøytiske salgsdata og finner at gradient boosting-metoder, særlig XGBoost, ofte gir lavere prognosefeil enn tradisjonelle modeller. Samtidig viser resultatene at enklere statistiske modeller i enkelte tilfeller kan prestere like godt når

tidsseriene har tydelige sesongmønstre. Dette indikerer at modellvalg bør tilpasses datagrunnlagets egenskaper, og at økt modellkompleksitet ikke nødvendigvis gir bedre prognoser.

Andre studier peker på at maskinlæringsmetoder kan være særlig nyttige når datastrukturen er mer kompleks, for eksempel når etterspørselen påvirkes av flere produkter eller ulike nivåer i forsyningskjeden. Zhu et al. (2021) viser at maskinlæringsmodeller kan forbedre prognosenøyaktigheten når informasjon fra flere relaterte tidsserier analyseres samlet. Samtidig understrekes det i litteraturen at slike modeller ofte krever større datamengder og mer omfattende modelltilpasning enn tradisjonelle tidsseriemodeller.

Til tross for den økende interessen for maskinlæringsmetoder er det fortsatt usikkerhet knyttet til hvor stor praktisk merverdi disse metodene gir i situasjoner der datagrunnlaget er relativt begrenset. Mange virksomheter opererer med relativt korte tidsserier og moderate datamengder, noe som kan redusere fordelene ved mer komplekse modeller. Dette er særlig relevant i operativ logistikkplanlegging, hvor modellene må være både robuste og praktisk anvendbare.

På bakgrunn av denne forskningen fremstår en sammenligning mellom klassiske tidsseriemodeller og nyere maskinlæringsmetoder som et relevant forskningsbidrag. Denne rapporten bygger videre på eksisterende litteratur ved å undersøke hvordan Holt–Winters og ARIMA presterer på et datasett bestående av månedlige leveranser fra et sentrallager til grossister. I tillegg inkluderes XGBoost som en maskinlæringsbasert metode for å undersøke om en mer datadrevet modell gir bedre prognosepresisjon enn de tradisjonelle modellene.

Studien bidrar dermed til den eksisterende forskningen ved å analysere reelle logistikkdata fra 105 varelinjer over en periode på 48 måneder. Samtidig adresserer den et praktisk relevant spørsmål innen operativ etterspørselsplanlegging: om økt modellkompleksitet faktisk gir bedre prognoser i en distribusjonskontekst med relativt begrenset historisk datagrunnlag.

Teori

Etterspørselsprognoser er en sentral del av beslutningsgrunnlaget i logistikk og supply chain management. Prognoser brukes til å planlegge lagerbeholdning, produksjon og distribusjon, og prognosenøyaktighet kan derfor ha direkte konsekvenser for både kostnader og servicenivå i en virksomhet. I praksis innebærer etterspørselsprognoser å bruke historiske data til å estimere fremtidig etterspørsel ved hjelp av statistiske eller datadrevne modeller.

Innen prognoseteori er eksponentiell glatting og ARIMA blant de mest etablerte modellene for tidsserieprognoser. Eksponentiell glatting bygger på prinsippet om at nyere observasjoner bør tillegges større vekt enn eldre observasjoner. Holt–Winters-modellen utvider denne tilnærmingen ved å inkludere separate komponenter for nivå, trend og sesong (Hyndman & Athanasopoulos, 2021).

ARIMA-modeller beskriver tidsserier gjennom autoregressive komponenter, differensiering og glidende gjennomsnitt. Disse modellene er spesielt nyttige når dataserier viser statistisk avhengighet mellom tidligere observasjoner og prognosefeil (Hyndman & Athanasopoulos, 2021).

I nyere forskning har maskinlæringsmetoder blitt stadig mer brukt i prognoseoppgaver. Slike modeller kan identifisere komplekse mønstre i data uten å anta en bestemt statistisk struktur. Samtidig understrekes det i litteraturen at mer komplekse modeller ikke nødvendigvis gir bedre prognoser enn enklere modeller når dataseriene er korte eller relativt stabile (Hyndman & Athanasopoulos, 2021; Petropoulos et al., 2022)

Klassiske tidsseriemodeller

Tradisjonelle prognosemetoder innen logistikk og operasjonsanalyse er ofte basert på statistisk tidsserieanalyse. Slike modeller antar at historiske observasjoner inneholder informasjon om fremtidige verdier gjennom trend, sesongmønstre og autokorrelasjon. En av de mest brukte modellene i operativ etterspørselsplanlegging er Holt–Winters-metoden, som er en videreutvikling av eksponentiell glatting. Modellen dekomponerer tidsserien i tre komponenter: nivå, trend og sesong, og er derfor spesielt egnet for dataserier med stabile sesongmønstre (Hyndman & Athanasopoulos, 2018).

En annen mye brukt metode er ARIMA-modellen (Autoregressive Integrated Moving Average). ARIMA beskriver tidsserien gjennom statistiske sammenhenger mellom tidligere observasjoner og tidligere prognosefeil. Modellen kan være fleksibel når tidsserien ikke viser en tydelig eller stabil sesongstruktur (Box et al., 2015). Flere studier innen etterspørselsprognoser viser at slike statistiske modeller fortsatt kan gi gode resultater i praktiske anvendelser, særlig når dataseriene er relativt korte og strukturen i dataene er stabil (Petropoulos et al., 2022).

Innen farmasøytisk retail viser Burinskiene (2022) at prognosenøyaktighet påvirkes både av modellvalg og av hvordan dataene struktureres. Studien viser blant annet at prognoser utviklet på et mer detaljert nivå i distribusjonskjeden kan gi bedre presisjon enn mer aggregerte analyser. I tillegg fremheves betydningen av datakvalitet, blant annet gjennom håndtering av outliers og perioder med mangel på varer.

Maskinlæringsbaserte prognosemodeller

I nyere forskning har det vært økende interesse for maskinlæringsmetoder innen etterspørselsprognoser. Maskinlæring skiller seg fra tradisjonelle tidsseriemodeller ved at modellene ikke nødvendigvis forutsetter en bestemt statistisk struktur i dataene. I stedet lærer modellene mønstre direkte fra data gjennom algoritmer som optimaliserer prediksjonsfeil.

En metode som har fått særlig oppmerksomhet er XGBoost (Extreme Gradient Boosting), som er en ensemblemetode basert på gradient boosting av beslutningstrær (Chen & Guestrin, 2016). Metoden er utviklet for å håndtere store datasett og komplekse mønstre i dataene, og har vist gode resultater innen en rekke prediksjonsoppgaver.

Flere nyere studier har undersøkt bruken av maskinlæring i etterspørselsprognoser. Fourkiotis og Tsadiras (2024) sammenligner statistiske modeller og maskinlæringsmetoder på farmasøytiske salgsdata og finner at gradient boosting-metoder, særlig XGBoost, ofte gir lavere prognosefeil enn tradisjonelle modeller. Samtidig viser resultatene at enklere statistiske modeller kan prestere like godt i situasjoner der tidsserieene har tydelige sesongmønstre.

Andre studier peker på at maskinlæringsmodeller kan være spesielt nyttige når datastrukturen er mer kompleks, for eksempel når etterspørselen påvirkes av flere produkter eller ulike nivåer i forsyningskjeden. Zhu et al. (2021) viser at maskinlæringsmodeller kan forbedre prognosenøyaktigheten når informasjon fra flere relaterte tidsserier analyseres samlet. Dette er særlig relevant i situasjoner der datamengden per produkt er begrenset.

Uenigheter i forskningen

Til tross for den økende interessen for maskinlæringsmetoder er det fortsatt uenighet i litteraturen om hvorvidt slike metoder alltid gir bedre prognoser enn tradisjonelle statistiske modeller. Enkelte studier finner at maskinlæringsmodeller gir lavere prognosefeil, mens andre studier viser at enklere modeller kan prestere like godt eller bedre når dataseriene er korte eller relativt stabile (Petropoulos et al., 2022).

En viktig diskusjon i forskningen handler derfor om forholdet mellom modellkompleksitet og praktisk nytte. Mer avanserte modeller kan være vanskeligere å implementere og tolke i praksis, og økt kompleksitet gir ikke nødvendigvis bedre beslutningsgrunnlag i operative planleggingsprosesser.

Forskningsgap og plassering av studien

Til tross for omfattende forskning på etterspørselsprognoser er det fortsatt behov for empiriske studier som analyserer prognosemetoder på reelle logistikkdata. Mange studier er basert på offentlige datasett eller simulert data, mens færre studier undersøker hvordan ulike modeller presterer i konkrete distribusjonskontekster.

Denne studien bidrar til litteraturen ved å analysere prognosemetoder på et datasett bestående av månedlige leveranser fra et sentrallager til grossister. Datasettet omfatter 105 varelinjer over en periode på 36 måneder og representerer derfor et realistisk beslutningsgrunnlag i operativ logistikkplanlegging.

Studien undersøker spesielt hvorvidt ARIMA gir bedre prognosepresisjon enn Holt–Winters, samt om en maskinlæringsbasert metode som XGBoost kan gi ytterligere forbedringer. Dermed belyser studien et praktisk relevant spørsmål innen etterspørselsprognoser: om mer avanserte modeller faktisk gir bedre prediksjoner enn tradisjonelle statistiske metoder i en logistikkontekst med relativt begrenset historisk datagrunnlag.

Casebeskrivelse

Bakgrunn for problemstillingen

Studien tar utgangspunkt i en farmasøytisk virksomhet som distribuerer legemidler fra et europeisk sentrallager til flere grossister i Norge. Virksomheten opererer i en bransje hvor høy leveringspålitelighet er avgjørende, ettersom legemidler ofte er kritiske produkter hvor mangel kan få direkte konsekvenser for både pasienter og helsevesen. Samtidig er det viktig å unngå unødvendig lagerbinding og svinn, særlig fordi enkelte legemidler har begrenset holdbarhet.

For å håndtere denne balansen er virksomheten avhengig av gode etterspørselsprognoser. Prognosene brukes blant annet til å planlegge lagerbeholdning i sentrallageret og til å koordinere leveranser til grossistene. Feilprognoser kan føre til enten for lave lagernivåer, med risiko for mangelsituasjoner, eller for høye lagernivåer, noe som kan gi økte kostnader og risiko for kassasjon.

Datagrunnlaget som benyttes i denne studien består av månedlige leveranser fra sentrallageret til grossister i Norge. Datasettet omfatter 105 varelinjer over en periode på 48 måneder og representerer derfor et realistisk bilde av etterspørselen som virksomheten må planlegge for. Leveransene til grossistene fungerer i denne sammenhengen som et mål på etterspørselen i markedet.

I dag benytter virksomheten egne interne prognoser som grunnlag for planlegging. Studenten har imidlertid ikke direkte tilgang til de interne prognosemodellene. Dette prosjektet tar derfor utgangspunkt i tilgjengelige historiske leveransedata for å undersøke hvordan ulike prognosemetoder kan brukes til å predikere fremtidig etterspørsel.

En sentral utfordring i dette arbeidet er å velge en prognosemodell som både gir tilstrekkelig presisjon og samtidig er praktisk anvendbar i en operativ logistikkontekst. I litteraturen diskuteres ofte hvorvidt mer

avanserte modeller gir bedre prognoser enn enklere statistiske metoder. På bakgrunn av dette undersøker studien hvordan to etablerte tidsseriemodeller, Holt–Winters og ARIMA, presterer på virksomhetens data. I tillegg vurderes en maskinlæringsbasert metode (XGBoost) for å analysere om en mer datadrevet modell kan gi forbedret prognosepresisjon.

Formålet er dermed å analysere hvorvidt mer avanserte prognosemetoder gir bedre prediksjoner enn enklere modeller i en praktisk distribusjonskontekst med relativt begrenset historisk datagrunnlag.

Metode

Studien er gjennomført som en kvantitativ casestudie basert på historiske leveransedata fra én virksomhet. Formålet er å sammenligne prognosepresisjon på tvers av fire modeller ved bruk av identiske data og evalueringsmetoder.

Forskningsdesign

Studien følger et komparativt evalueringsdesign der fire prognosemodeller — naiv, Holt-Winters, ARIMA og XGBoost — sammenlignes på det samme datasettet under identiske betingelser. Designet er i tråd med standard evalueringspraksis i tidsserieprognostisering, der modeller evalueres ved hjelp av felles feilmål og hold-out-validering (Hyndman & Athanasopoulos, 2021).

Kvantitativ metode

Studien er utelukkende kvantitativ og baserer seg på numeriske leveransedata. Det er ikke gjennomført intervjuer, spørreundersøkelser eller kvalitativ analyse. Datagrunnlaget er hentet fra virksomhetens ERP-system og analysert ved hjelp av statistiske og maskinlæringsbaserte modeller.

Analyseverktøy

Analysen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `pmdarima`, `xgboost`, `pandas`, `numpy`, `matplotlib` og `scikit-learn`. Python er valgt fordi det gir fri tilgang til oppdaterte implementasjoner av alle fire modellene, og fordi analysekoden kan gjøres transparent og reproduserbar.

Etiske betraktninger

Datasettet er anonymisert av studenten i tråd med virksomhetens retningslinjer for bruk av data i KI-verktøy og akademisk forskning. Anonymiseringen sikrer at hverken produktidentitet eller bedriftsinformasjon kan identifiseres av tredjeparter.

Potensielle feilkilder

De viktigste feilkildene er diskutert i avsnitt 9.4. De mest sentrale er: (1) leveranser til grossister som proxy for sluttetterspørsel, (2) asymmetri mellom individuell modellering (Holt-Winters/ARIMA) og global modellering (XGBoost), og (3) begrenset datamengde for maskinlæringsformål.

Data

Datagrunnlaget i studien består av historiske salgsdata hentet fra virksomhetens interne ERP-system. Dataene er anonymisert før de ble brukt i prosjektet for å sikre konfidensialitet knyttet til både produkter og virksomhet.

Datasettet inneholder månedlige leveransevolumer fra et europeisk sentrallager til grossister i Norge. Leveransene brukes i denne studien som en proxy for etterspørsel i markedet.

Hvordan dataene er samlet inn

Dataene er hentet direkte fra virksomhetens ERP-system av studenten som arbeider i virksomheten. Uttrekket ble gjort som en eksport av historiske salgsdata til Excel-format. Før analysen ble datasettet anonymisert slik at produktidentitet og bedriftsinformasjon ikke kan identifiseres.

Det er ikke gjennomført intervjuer eller spørreundersøkelser i forbindelse med datainnsamlingen. All kvantitativ analyse i studien baseres på historiske salgsdata.

Tidsperiode

Datasettet dekker perioden: **Januar 2022 – desember 2025**

Dette gir totalt **48 månedlige observasjoner per varelinje** i rådatasettet.

For analyseformål vil det kunne bli brukt en noe kortere tidsperiode dersom enkelte serier inneholder manglende observasjoner eller dersom dataseriene må tilpasses modellkravene.

Data fra ERP-systemet

Datasettet inneholder:

105 varelinjer (SKU-er)

månedlige leveransevolumer

opptil **48 observasjoner per varelinje**

Totalt inneholder rådatasettet omtrent:

5 040 potensielle observasjoner (105 × 48 måneder).

Etter datarensing (data cleaning) kan antall brukbare observasjoner være noe lavere, ettersom enkelte varelinjer inneholder manglende verdier i deler av tidsperioden. Datarensingen vil blant annet bestå av:

håndtering av manglende verdier

kontroll av ekstreme observasjoner

eventuelt fjerning av ufullstendige tidsserier

Tilgang til data

Datasettet er hentet fra virksomhetens interne ERP-system og kan derfor ikke gjøres offentlig tilgjengelig i sin opprinnelige form. De anonymiserte dataene er kun brukt til analyse i denne studien. Strukturen i datasettet og metodene som er brukt i analysen er imidlertid beskrevet slik at tilsvarende analyser kan gjennomføres på andre datasett med tilsvarende struktur.

Databehandling (Data Cleaning)

Før analysen ble datasettet kontrollert og klargjort for statistisk modellering. Formålet med datarensingen var å sikre konsistens i tidsseriene og redusere risikoen for at feil i data påvirker prognosemodellene. Håndtering av manglende observasjoner og outliers er en viktig del av tidsserieanalyse, ettersom slike forhold kan påvirke både modelltilpasning og prognosepresisjon (Hyndman & Athanasopoulos, 2021). Følgende steg ble gjennomført: kontroll av manglende observasjoner i tidsseriene, kontroll av ekstreme verdier (outliers), sikring av konsistent tidsstruktur med én observasjon per måned og konvertering av dato til månedlig tidsindeks. Manglende observasjoner ble håndtert ved å kontrollere om de skyldtes manglende salg eller manglende registrering. Dersom observasjonen representerte reelt nullsalg, ble verdien beholdt. Dersom observasjonen skyldtes manglende registrering, ble den enten korrigert eller ekskludert fra analysen. Etter datarensing besto datasettet av komplette månedlige tidsserier som kunne brukes til sammenligning av prognosemodeller.

Beskrivelse av datasettet

Variabel	Beskrivelse
Antall produkter (SKU)	105
Datakilde	ERP-system
Geografisk område	Norge
Distribusjonsledd	Europeisk sentrallager til grossister i Norge
Tidsperiode	Jan 2022 – Des 2025
Observasjonsnivå	Måned
Maks observasjoner per SKU	48
Totalt antall potensielle observasjoner	5 040

Modellering

6.1 Modelleringsrammeverk

Modelleringen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `xgboost` og `pandas`. Alle modeller er implementert og evaluert etter et felles rammeverk for å sikre sammenlignbarhet på tvers av metodene.

Datasettet er delt inn i et treningssett og et testsett ved hjelp av en *hold-out*-strategi. Treningssettet består av de første 36 månedene (januar 2022 – desember 2024), mens testsettet består av de siste 12 månedene (januar 2025 – desember 2025). Denne inndelingen er valgt fordi testperioden dekker én full sesongssyklus, noe som gjør det mulig å evaluere modellenes evne til å predikere sesongvariasjoner. Hold-out-evaluering er i tråd med standard praksis i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Alle 105 varelinjer modelleres separat, i tråd med antagelsen om uavhengige tidsserier. Prognosehorisonten er 12 måneder, og alle modeller produserer etterskuddsprognoser (*out-of-sample*) for testperioden.

6.2 Evaluering

Modellene evalueres ved hjelp av tre komplementære feilmål:

- **RMSE** (Root Mean Squared Error) — straffes strengt for store avvik
- **MAE** (Mean Absolute Error) — robust mot ekstremverdier
- **MAPE** (Mean Absolute Percentage Error) — sammenlignbar på tvers av varelinjer med ulike volumnivåer

Feilmålene beregnes per varelinje og aggregeres deretter til gjennomsnittsverdier på tvers av alle 105 SKU-er for sammenligning på modellnivå.

6.3 Naiv prognose (referansemodell)

Den naive prognosen benyttes som referansepunkt (*baseline*). Modellen predikerer neste måneds etterspørsel som lik den observerte etterspørselen i tilsvarende måned foregående år (sesongnaiv prognose). Dette gir et minimumsnivå som øvrige modeller forventes å forbedre.

6.4 Holt-Winters eksponentiell glatting

Holt-Winters-metoden implementeres ved bruk av `ExponentialSmoothing` fra `statsmodels`. Modellen inkluderer tre komponenter: nivå (α), trend (β) og sesong (γ), med multiplikativ sesong der dataene tilsier det og additiv sesong ellers. Sesonglengden settes til 12 for månedlige data.

Parameterne α, β og γ estimeres automatisk ved minimering av SSE (*sum of squared errors*) over treningssettet. Valget mellom additiv og multiplikativ sesongkomponent gjøres individuelt per varelinje basert på variasjonskoeffisienten i dataene.

6.5 ARIMA

ARIMA-modellen implementeres ved bruk av `auto_arima` fra biblioteket `pmdarima`, som automatisk identifiserer de optimale parameterne *(p, d, q)* og sesongparameterne *(P, D, Q, m=12)* via informasjonskriteriet AIC. En sesongutvidet SARIMA-modell benyttes der testene indikerer statistisk signifikant sesongstruktur i residualene.

Stasjonaritet kontrolleres ved hjelp av ADF-testen (*Augmented Dickey-Fuller*). Dersom serien ikke er stasjonær, differensieres den inntil stasjonaritet er oppnådd.

6.6 XGBoost

XGBoost implementeres ved bruk av `xgboost`-biblioteket. Ettersom XGBoost ikke modellerer tidsserier direkte, transformeres problemet til en supervisert læringsoppgave ved hjelp av *feature engineering*. Følgende forklaringsvariabler konstrueres for hver observasjon:

- **Lag-variabler**: etterspørsel for t-1, t-2, t-3 og t-12 måneder
- **Sesongindikator**: månedsnummer (1–12) som kategorisk variabel
- **Trend**: lineær tidsindeks

Modellen trenes på alle 105 varelinjer samlet (*global modell*), noe som gjør det mulig å utnytte informasjon på tvers av produkter. Hyperparametrene (antall trær, læringsrate og treedybde) optimaliseres via krysskalibrering (*time series cross-validation*) på treningssettet.

Analyse

7.1 Utforskende dataanalyse

Før modellering gjennomføres en utforskende dataanalyse (*exploratory data analysis*, EDA) for å kartlegge egenskapene til tidsseriene. Formålet er å danne et empirisk grunnlag for modelleringsvalg og for tolkning av resultatene.

Følgende elementer inngår i den utforskende analysen:

- **Visualisering av tidsserier**: Utvalgte varelinjer plottes for å identifisere trend, sesongmønstre og eventuelle strukturelle brudd i dataperioden.
- **Dekomponering**: Tidsseriene dekomponeres i komponentene nivå, trend og sesong ved bruk av STL-dekomponering (*Seasonal and Trend decomposition using Loess*) for å kartlegge om sesongmønsteret er stabilt over tid.
- **Stasjonaritetstesting**: ADF-testen benyttes for å vurdere om seriene er stasjonære, som er en forutsetning for ARIMA-modellering.
- **Beskrivende statistikk**: Gjennomsnitt, standardavvik og variasjonskoeffisient beregnes per varelinje for å beskrive spredningen i etterspørsel på tvers av produktporteføljen.

Den utforskende analysen gjennomføres på treningssettet alene for å unngå datalekkasje (*data leakage*) fra testsettet inn i modellutformingen.

7.2 Evalueringsdesign

Alle fire modeller evalueres etter et felles evalueringsdesign for å sikre sammenlignbarhet. Prinsippet om én felles prognosehorisont (12 måneder) og identisk train/test-split (36/12 måneder) benyttes konsekvent for samtlige varelinjer og modeller.

For hver varelinje og modell beregnes RMSE, MAE og MAPE. Feilmålene aggregeres til medianverdier på tvers av alle 105 SKU-er. Median benyttes fremfor gjennomsnitt da fordelingen av feilmål på tvers av varelinjer forventes å inneholde ekstreme verdier for varelinjer med lavt volum eller uregelmessig etterspørsel.

7.3 Klassifisering av tidsserier

For å nyansere analysen klassifiseres tidsseriene i undergrupper basert på etterspørselskarakteristika. Dette gjøres for å undersøke om modellenes relative prestasjon varierer med egenskapene til dataseriene. Klassifiseringen gjennomføres langs to dimensjoner:

- **Volumnivå**: Høy, middels og lav gjennomsnittlig månedlig etterspørsel
- **Sesongstyrke**: Basert på styrken av sesongkomponenten fra STL-dekomponeringen

Resultatene analyseres både samlet og per undergruppe for å avdekke om én modell er konsistent overlegen, eller om ulike modeller er best egnet for ulike typer varelinjer.

7.4 Statistisk sammenligning

For å vurdere om forskjellene mellom modellenes prognosepresisjon er statistisk signifikante, gjennomføres en **Diebold-Mariano-test** (Diebold & Mariano, 1995) mellom Holt-Winters og ARIMA, som er studiens primære sammenligningspar. Testen vurderer om én modell systematisk gir lavere prognosefeil enn den andre, og gir et statistisk grunnlag for å besvare problemstillingen.

Resultat

Dette kapittelet presenterer resultatene fra den utforskende dataanalysen og sammenligningen av prognosemodellene. Resultatene presenteres objektivt og uten tolkning — tolkning og diskusjon følger i kapittel 9.0.

8.1 Utforskende dataanalyse

Den utforskende analysen viser at de 105 varelinjene varierer betydelig i etterspørselsnivå og mønster. Tabell 1 oppsummerer beskrivende statistikk for hele produktporteføljen over treningsperioden.

Tabell 1: Beskrivende statistikk for treningssettet (Jan 2022 – Des 2024)

Statistikk	Verdi
Antall SKU-er	105
Median månedlig etterspørsel (pakninger)	1 022
Gjennomsnittlig månedlig etterspørsel	2 521
Andel SKU-er med tydelig sesongmønster	70,5 %
Andel SKU-er med positiv trend	53,3 %
Andel SKU-er med nullverdier i tidsserien	76,2 %

Figur 1 viser et eksempel på prognose for én varelinje sammenlignet med faktisk etterspørsel i testperioden.

> ***[Figur 1: figur1_eksempel_prognose.png — sett inn figur her]***

Datasettet inneholder 105 varelinjer med månedlige observasjoner over perioden januar 2022 til desember 2025 (48 måneder totalt). Etter datarensing besto alle 105 tidsserier av komplette observasjoner egnet for modellering.

8.2 Prognosepresisjon — samlede resultater

Tabell 2 presenterer medianverdiene for RMSE, MAE og MAPE på tvers av alle 105 varelinjer i testperioden (Jan 2025 – Des 2025).

Tabell 2: Samlet prognosepresisjon per modell (median over 105 SKU-er, testperiode Jan–Des 2025)

Modell	RMSE	MAE	MAPE (%)
Naiv (sesongnaiv)	1131,65	914,58	67,50
Holt-Winters	935,84	769,90	62,49
ARIMA / SARIMA	846,20	820,01	57,77
XGBoost	757,23	654,94	51,97

Figur 2 viser median MAPE per modell og illustrerer den relative forbedringen fra naiv prognose til XGBoost.

> ***[Figur 2: figur2_mape_sammenligning.png — sett inn figur her]***

8.3 Resultater per undergruppe

Tabell 3 viser median MAPE fordelt på varelinjer med henholdsvis tydelig og svakt sesongmønster.

Tabell 3: Median MAPE etter sesongstyrke

Modell	Tydelig sesong	Svak/ingen sesong
Naiv	70,20 %	59,95 %
Holt-Winters	64,26 %	59,34 %
ARIMA	63,09 %	49,50 %
XGBoost	62,86 %	39,37 %

Tabell 4 viser tilsvarende sammenligning fordelt på volumnivå (høy, middels, lav).

Tabell 4: Median MAPE etter volumnivå

Modell	Høyt volum	Middels volum	Lavt volum
Naiv	58,11 %	68,02 %	86,07 %
Holt-Winters	60,85 %	63,84 %	62,49 %
ARIMA	52,21 %	60,20 %	61,48 %
XGBoost	45,52 %	51,53 %	82,33 %

8.4 Statistisk test

Diebold-Mariano-testen mellom Holt-Winters og ARIMA gir følgende resultat:

Tabell 5: Diebold-Mariano-test (Holt-Winters vs. ARIMA)

	Verdi
DM-statistikk	1,508
p-verdi	0,132
Konklusjon	Ingen statistisk signifikant forskjell (p > 0,05)

Diskusjon

Dette kapittelet diskuterer resultatene fra analysen opp mot problemstillingen, eksisterende litteratur og praktiske implikasjoner for logistikkplanlegging. Der resultatene avviker fra forventningene, drøftes mulige forklaringer.

9.1 Svar på problemstillingen

Studiens problemstilling er:

> *Hvilken prognosemodell gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system, gitt et datasett på 48 måneder og 105 produkter?*

Resultatene viser at XGBoost gir lavest median MAPE på tvers av de 105 varelinjene, med en verdi på 51,97 % mot 57,77 % for ARIMA og 62,49 % for Holt-Winters. XGBoost er overlegen på alle tre feilmål — RMSE (757,23), MAE (654,94) og MAPE (51,97 %) — sammenlignet med samtlige øvrige modeller. Alle fire modeller forbedrer seg konsistent over den naive referanseprognosen, som hadde en median MAPE på 67,50 %.

Svaret på problemstillingen er dermed at XGBoost gir høyest prediksjonsnøyaktighet under de betingelsene som er analysert i denne studien. Resultatet bør imidlertid tolkes med forbehold, da XGBoost her er implementert som en global modell som utnytter mønstre på tvers av alle 105 SKU-er, mens Holt-Winters og ARIMA er tilpasset individuelt per varelinje.

9.2 Sammenligning med litteraturen

Resultatene støtter eksisterende forskning på feltet.

Fourkiotis og Tsadiras (2024) finner at XGBoost typisk gir lavere prognosefeil enn tradisjonelle statistiske modeller på farmasøytiske salgsdata. Dette er konsistent med funnene i denne studien, der XGBoost gir en MAPE-forbedring på 15,53 prosentpoeng sammenlignet med den naive prognosen og 10,52 prosentpoeng over Holt-Winters. Forbedringen er imidlertid moderat, og de klassiske modellene (Holt-Winters og ARIMA) presterer fortsatt vesentlig bedre enn referansenivået.

Burinskiene (2022) påpeker at datakvalitet og struktureringsnivå er like viktig som modellvalg. Dette er relevant for forståelsen av hvorfor Holt-Winters og ARIMA yter relativt godt på dette datasettet: leveransedataene fra et sentrallager-grossist-system har en relativt stabil struktur med begrenset støy, noe som favoriserer klassiske tidsseriemodeller.

Hyndman og Athanasopoulos (2021) og Petropoulos et al. (2022) argumenterer for at enkle modeller ofte presterer like godt som komplekse modeller på korte tidsserier. Studiens resultater utfordrer delvis dette synet — XGBoost gir konsistent lavere feilmål — men bekrefter samtidig at forskjellene er relativt moderate, og at Holt-Winters gir akseptabel prognosepresisjon med langt lavere implementeringskompleksitet.

Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA (DM = 1,508, p = 0,132). Dette indikerer at de to klassiske metodene er likeverdige i presisjonsevne på dette datasettet, til tross for at ARIMA gir noe lavere RMSE og MAPE i gjennomsnitt.

9.3 Modellkompleksitet og praktisk nytte

Et sentralt spørsmål i litteraturen er om økt modellkompleksitet gir reell merverdi i operativ planlegging. Resultatene i denne studien viser at XGBoost gir den beste prognosepresisjon, men forbedringen over Holt-Winters på MAPE er på om lag 10,5 prosentpoeng. Spørsmålet er om denne gevinsten forsvarer den økte implementeringskompleksiteten.

For virksomheter med tilgjengelig datakompetanse og Python-infrastruktur vil XGBoost være et godt valg. For virksomheter med begrensede analytiske ressurser vil Holt-Winters gi tilfredsstillende prognoser med langt lavere krav til vedlikehold og tolkning. Dette er særlig relevant i farmasøytisk distribusjon, hvor leveringspålitelighet og forutsigbarhet veier tyngre enn marginal presisjonsgevinst.

Videre er det verdt å merke seg at ARIMA ikke gir signifikant bedre prognoser enn Holt-Winters (p = 0,132), noe som taler mot den ekstra modelltilpasningskostnaden ARIMA krever i form av parametervalg

og stasjonaritetstesting.

9.4 Metodiske begrensninger

Studien har flere begrensninger som bør tas i betraktning ved tolkning av resultatene:

Leveranser som proxy for etterspørsel: Datasettet representerer leveranser fra sentrallager til grossister, ikke sluttkundesalg. Bullwhip-effekter kan medføre at modellene fanger opp variasjoner i bestillingsatferd snarere enn reell sluttetterspørsel.

Kort historikk for XGBoost: Med 36 måneder treningsdata per varelinje er datagrunnlaget relativt begrenset for en maskinlæringsmodell. XGBoost er generelt best egnet for større datasett, og resultatene kan derfor ikke uten videre generaliseres til situasjoner med lengre historikk. Med mer data ville XGBoost potensielt gitt enda større fordel over de klassiske modellene.

Uavhengige varelinjer: Holt-Winters og ARIMA er modellert individuelt per varelinje, mens XGBoost er trent som en global modell på alle 105 SKU-er. Denne asymmetrien kan ha gitt XGBoost en fordel, og resultatene bør tolkes i lys av dette metodiske valget.

Ekstern validitet: Resultatene gjelder ett distribusjonsselskap i én bransje. Overførbarheten til andre bransjer eller distribusjonssystemer er begrenset.

9.5 Implikasjoner for næringslivet

For virksomheter i farmasøytisk distribusjon med tilsvarende datastruktur gir studien følgende praktiske implikasjoner:

- **XGBoost** anbefales som prognosemodell der datakompetanse og Python-infrastruktur er tilgjengelig, særlig for virksomheter med mange SKU-er som kan dra nytte av en global modell.
- **Holt-Winters** anbefales som et robust og enkelt alternativ for virksomheter uten avansert analysekapasitet — modellen gir akseptabel presisjon og er lett å implementere og vedlikeholde.
- Det er ikke grunnlag for å foretrekke ARIMA over Holt-Winters på dette datasettet, gitt at Diebold-Mariano-testen ikke viser signifikant forskjell og ARIMA krever mer kompleks modelltilpasning.
- For varelinjer med lavt volum eller uregelmessig etterspørsel bør prognosene suppleres med manuell vurdering, da alle modeller viser høyere prognosefeil i denne gruppen.

Konklusjon

Denne studien har undersøkt hvilken prognosemodell som gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system. Fire modeller ble sammenlignet på et datasett bestående av 105 varelinjer over 48 måneder: naiv prognose, Holt-Winters eksponentiell glatting, ARIMA og XGBoost.

Resultatene viser at XGBoost gir høyest samlet prognosepresisjon målt ved alle tre feilmål — RMSE (757,23), MAE (654,94) og MAPE (51,97 %) — i testperioden januar til desember 2025. ARIMA presterer bedre enn Holt-Winters på RMSE og MAPE, men forskjellen er ikke statistisk signifikant (DM = 1,508, p = 0,132). Alle modeller forbedrer seg over den naive referanseprognosen, som hadde en median MAPE på 67,50 %.

Analysen viser at XGBoost, implementert som en global modell trent på alle 105 SKU-er, utnytter mønstre på tvers av produktporteføljen på en måte de individuelle tidsseriemodellene ikke gjør. Forbedringen over Holt-Winters er på om lag 10,5 prosentpoeng i MAPE, noe som er praktisk relevant, men som bør veies mot den økte implementeringskompleksiteten.

Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA, noe som svekker grunnlaget for å foretrekke den mer komplekse ARIMA-modellen i operativ planlegging.

Studien bidrar til den eksisterende forskningen ved å analysere prognosemetoder på reelle distribusjonsdata fra farmasøytisk sektor med 105 SKU-er og 48 måneder. Funnene støtter Fourkiotis og Tsadiras (2024), som viser at maskinlæringsmetoder som XGBoost gir lavere prognosefeil enn klassiske statistiske modeller på farmasøytiske data, men bekrefter samtidig at klassiske modeller som Holt-Winters gir akseptabel presisjon til en langt lavere implementeringskostnad.

10.1 Videre forskning

Denne studien reiser flere spørsmål som kan være utgangspunkt for videre forskning:

- **Lengre historikk:** En tilsvarende studie med lengre tidsserier (f.eks. 72–96 måneder) ville gi et bedre grunnlag for å vurdere XGBoosts potensial som global prognosemodell.
- **Hierarkisk prognosering:** Fremtidige studier kan undersøke om prognoser på aggregert nivå (f.eks. terapeutisk kategori) gir bedre presisjon enn prognoser per varelinje.
- **Hybrid-modeller:** Kombinasjoner av klassiske og maskinlæringsbaserte metoder er et voksende forskningsfelt som kan gi bedre resultater enn enkeltstående modeller.

- **Eksogene variabler:** Inkludering av eksterne faktorer som sesonginfluensa, legemiddelmangel eller regulatoriske endringer kan forbedre prognosenøyaktigheten for utvalgte produktkategorier.

Bibliografi

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.

Burinskiene, A. (2022). Forecasting model: The case of the pharmaceutical retail. *Frontiers in Medicine, 9*, 582186. https://doi.org/10.3389/fmed.2020.582186

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263. https://doi.org/10.1080/07350015.1995.10524599

Fourkiotis, K. P., & Tsadiras, A. K. (2024). Applying machine learning and statistical forecasting methods for enhancing pharmaceutical sales predictions. *Forecasting, 6*(1), 170–186. https://doi.org/10.3390/forecast6010010

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. https://otexts.com/fpp3/

Lov om apotek (apotekloven). (2000). *Lov om apotek (LOV-2000-06-02-39)*. https://lovdata.no/dokument/NL/lov/2000-06-02-39

Petropoulos, F., Spiliotis, E., & Assimakopoulos, V. (2022). Forecasting: Theory and practice. *International Journal of Forecasting, 38*(3), 705–871. https://doi.org/10.1016/j.ijforecast.2021.11.001

Zhu, X., Ninh, A., Zhao, H., & Liu, Z. (2021). Demand forecasting with supply chain information and machine learning: Evidence in the pharmaceutical industry. *Production and Operations Management, 30*(10), 3231–3252. https://doi.org/10.1111/poms.13458

Vedlegg