LOG650 — Morten Eidsvåg

Abstract

Student: Morten Eidsvåg | **Emne:** LOG650 Forskningsprosjekt | **Arbeidsform:** Individuelt

Denne studien undersøker hvilken prognosemodell som gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system. Fire modeller sammenlignes på et anonymisert datasett bestående av 105 SKU-er over 48 måneder (januar 2022 – desember 2025): naiv sesongprognose, Holt-Winters eksponentiell glatting, ARIMA/SARIMA og XGBoost. Modellene trenes på de første 36 månedene og evalueres på de siste 12 månedene ved hjelp av feilmålene RMSE, MAE og MAPE (median over alle SKU-er).

Resultatene viser at XGBoost gir lavest prognosefeil på alle tre feilmål (MAPE: 51,97 %; RMSE: 757,23; MAE: 654,94), etterfulgt av ARIMA (MAPE: 57,77 %), Holt-Winters (MAPE: 62,49 %) og naiv prognose (MAPE: 67,50 %). Alle modeller forbedrer seg over referansenivået. Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA (DM = 1,508, p = 0,132). Segmentert analyse viser at XGBoost er særlig overlegen for SKU-er uten tydelig sesongmønster og for varelinjer med høyt volum, men presterer svakt på lavvolum-SKU-er (MAPE: 82,33 %).

Studien konkluderer med at XGBoost gir best prognosepresisjon som global modell, men at Holt-Winters er et robust og praktisk alternativ der avansert analysekapasitet ikke er tilgjengelig. Det er ikke grunnlag for å foretrekke ARIMA over Holt-Winters på dette datasettet.

Innhold

1.0 Innledning
  1.1 Problemstilling
  1.2 Avgrensinger
2.0 Teori og litteratur
3.0 Casebeskrivelse
4.0 Metode og data
  4.1 Metode
  4.2 Data
  4.3 Metodiske forutsetninger
5.0 Modellering
6.0 Analytisk rammeverk
7.0 Resultat
8.0 Diskusjon
9.0 Konklusjon
10.0 Bibliografi
Vedlegg

1.0 Innledning

Etterspørselsprognoser er sentrale i beslutningsprosessene innen logistikk og supply chain management. Prognoser danner grunnlaget for planlegging av produksjon, lagerbeholdning og distribusjon i forsyningskjeder (Hyndman & Athanasopoulos, 2021). Den farmasøytiske sektoren kjennetegnes av sesongvariasjoner, regulatoriske krav og høye krav til leveringspålitelighet. I Norge har man gjennom flere tiår bygget ned nasjonale beredskapslagre for legemidler. Tidligere hadde staten et mer direkte ansvar for beredskapslager gjennom Norsk Medisinaldepot (NMD). Etter innføringen av apotekloven 1. mars 2001 så ble dette i noen grad erstattet med minstekrav til leveringsgrad for legemidler (Lov om apotek §5-4).

Til tross for dette har Norge opplevd flere tilfeller av legemiddelmangel de senere årene. Slike mangelsituasjoner kan skyldes både globale forsyningsproblemer og mangelfulle etterspørselsprognoser. Feilprognoser kan føre til enten legemiddelmangel, med potensielle helsemessige konsekvenser, eller overlagring som gir økte kostnader og risiko for tapt salg.

Tradisjonelt har etterspørselsprognoser vært basert på statistiske tidsseriemodeller som eksponentiell glatting og ARIMA (Hyndman & Athanasopoulos, 2021). Eksponentiell glatting, inkludert Holt–Winters-metoden, er spesielt utviklet for tidsserier som inneholder både trend og sesongmønstre, og er derfor mye brukt i operativ etterspørselsplanlegging (Hyndman & Athanasopoulos, 2021). Innen farmasøytisk industri viser studier at Holt–Winters ofte gir tilfredsstillende prognosenøyaktighet når dataserier inneholder tydelige sesongkomponenter (Burinskiene, 2022).

Nyere forskning indikerer imidlertid at maskinlæringsmetoder kan håndtere mer komplekse og ikke-lineære mønstre i data. Spesielt har gradient boosting-metoder som XGBoost vist gode resultater i prognoseoppgaver hvor tradisjonelle modeller ikke fanger opp komplekse sammenhenger (Chen & Guestrin, 2016; Fourkiotis & Tsadiras, 2024).

Litteraturgjennomgangen viser derfor et metodisk spenn mellom klassiske statistiske modeller og nyere maskinlæringsmetoder. Samtidig er det fortsatt uklart i hvilken grad mer komplekse AI-modeller faktisk gir merverdi i

situasjoner med begrenset historikk og panelstruktur på produktnivå, slik mange distribusjonsbedrifter opererer med i praksis.

Denne rapporten undersøker derfor hvordan ulike prognosemodeller presterer på reelle distribusjonsdata fra et sentrallager til grossister, bestående av 105 varelinjer over en periode på 48 måneder. Studien søker å bidra med innsikt i hvilken modelltype som gir best balanse mellom prognosepresisjon, robusthet og operasjonell anvendbarhet i logistikkplanlegging.

Problemstilling

Med utgangspunkt i ovenstående aktualisering formuleres følgende problemstilling:

Hvilken prognosemodell gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system, gitt et datasett på 48 måneder og 105 produkter?

For å besvare problemstillingen sammenlignes fire prognosemodeller:

Naiv sesongprognose (referansemodell)
Holt–Winters eksponentiell glatting
ARIMA / SARIMA
XGBoost

Modellene evalueres ved hjelp av etablerte prognosenøyaktighetsmål som **RMSE, MAE og MAPE**, som er blant de mest brukte målene for å evaluere prognosemodeller i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Analysen søker ikke bare å identifisere hvilken modell som gir best prognosepresisjon, men også å diskutere hvorvidt økt modellkompleksitet gir reell merverdi i et praktisk planleggingsperspektiv.

Avgrensinger

For å sikre analytisk presisjon gjøres følgende avgrensninger:

Datasett: Studien benytter kun historiske leveransedata (månedlig volum). Eksterne forklaringsvariabler som pris, kampanjer, demografi eller regulatoriske utfordringer inkluderes ikke.

Tidsperiode: Datasettet dekker totalt 48 måneder (januar 2022 – desember 2025), hvorav 36 måneder benyttes som treningssett og 12 måneder som testsett. Lengre historikk er ikke tilgjengelig og vurderes derfor ikke.

Horisont: Fokus er på kort- til mellomlangsiktig prognose relevant for lager- og produksjonsplanlegging.

Modellutvalg: Kun utvalgte representative modeller innen klassisk og nyere tidsserieanalyse er vurdert i denne oppgaven.

Struktur: Prognoser utvikles på varelinjenivå.

Disse avgrensningene gjør det mulig å analysere modellenes prestasjon under realistiske betingelser, samtidig som metodisk nøyaktighet opprettholdes.

2.0 Teori og litteratur

Etterspørselsprognoser er et sentralt forskningsområde innen logistikk og supply chain management, ettersom prognosenøyaktighet påvirker beslutninger knyttet til lagerstyring, produksjonsplanlegging og distribusjon (Hyndman & Athanasopoulos, 2021). I farmasøytisk sektor er dette særlig viktig, ettersom feilprognoser kan føre til legemiddelmangel og økt kapitalbinding i lager.

Klassiske tidsseriemodeller

Tradisjonelle prognosemetoder er basert på statistisk tidsserieanalyse og antar at historiske observasjoner inneholder informasjon om fremtidige verdier gjennom trend, sesongmønstre og autokorrelasjon. Holt–Winters-metoden er en videreutvikling av eksponentiell glatting som dekomponerer tidsserien i tre komponenter: nivå, trend og sesong. Metoden er spesielt egnet for dataserier med stabile sesongmønstre og brukes mye i operativ salgs- og lagerprognostisering (Hyndman & Athanasopoulos, 2018).

ARIMA (Autoregressive Integrated Moving Average) beskriver tidsserier gjennom statistiske sammenhenger mellom tidligere observasjoner og prognosefeil. Modellen kan tilpasses fleksibelt til serier uten tydelig sesongstruktur (Box et al., 2015), og studier viser at statistiske modeller fortsatt gir gode resultater ved korte og stabile dataserier (Petropoulos et al., 2022).

Innen farmasøytisk retail viser Burinskiene (2022) at prognosenøyaktighet påvirkes like mye av datakvalitet og struktureringsnivå som av selve modellvalget. Prognoser på et mer detaljert nivå i distribusjonskjeden gir bedre presisjon enn aggregerte analyser, og håndtering av outliers og mangelperioder er avgjørende for pålitelige resultater.

Maskinlæringsbaserte metoder

I nyere forskning har maskinlæringsmetoder fått stadig mer oppmerksomhet innen etterspørselsprognoser. Disse metodene skiller seg fra tradisjonelle modeller ved at de lærer mønstre direkte fra data uten å forutsette en bestemt statistisk struktur. XGBoost (Extreme Gradient Boosting) er en ensemblemetode basert på gradient boosting av beslutningstrær (Chen & Guestrin, 2016) og har vist sterke resultater i en rekke prediksjonsoppgaver.

Fourkiotis og Tsadiras (2024) sammenligner statistiske modeller og maskinlæringsmetoder på farmasøytiske salgsdata og finner at XGBoost typisk gir lavere prognosefeil enn tradisjonelle modeller, men at enklere statistiske modeller kan prestere like godt ved tydelige sesongmønstre. Zhu et al. (2021) viser at maskinlæringsmodeller kan forbedre prognosenøyaktigheten ytterligere ved å utnytte informasjon på tvers av relaterte tidsserier — særlig relevant for datasett med mange produkter og begrenset historikk per varelinje.

Uenigheter i forskningen

Til tross for den økte interessen for maskinlæringsmetoder er det fortsatt uenighet i litteraturen om hvorvidt slike metoder alltid er overlegne tradisjonelle modeller. Petropoulos et al. (2022) viser at enklere modeller kan prestere like godt eller bedre ved korte og relativt stabile dataserier. En sentral diskusjon handler om forholdet mellom modellkompleksitet og praktisk nytte: mer avanserte modeller er vanskeligere å implementere og tolke, og økt kompleksitet gir ikke nødvendigvis bedre beslutningsgrunnlag i operative planleggingsprosesser.

Forskningsgap og plassering av studien

Til tross for omfattende forskning er det fortsatt behov for empiriske studier på reelle logistikkdata. Mange studier benytter offentlige datasett eller simulert data, mens færre undersøker modellprestasjon i konkrete distribusjonskontekster med begrenset historikk. Denne studien bidrar til litteraturen ved å analysere fire prognosemodeller på månedlige leveranser fra et sentrallager til grossister — 105 SKU-er over 48 måneder — og adresserer et praktisk relevant spørsmål: om økt modellkompleksitet gir bedre prediksjoner i en logistikkontekst med moderat datagrunnlag.

3.0 Casebeskrivelse

Studien tar utgangspunkt i en farmasøytisk virksomhet som distribuerer legemidler fra et europeisk sentrallager til grossister i Norge. Virksomheten opererer i et marked hvor høy leveringspålitelighet er avgjørende — legemiddelmangel kan få direkte konsekvenser for pasienter og helsevesen. Samtidig er det kritisk å unngå overlagring, ettersom enkelte legemidler har begrenset holdbarhet og kassasjon representerer en direkte kostnad.

Studenten er ansatt i virksomheten og har hentet datasettet direkte fra ERP-systemet. Virksomheten benytter egne interne prognosemodeller, men disse er ikke tilgjengelige for studenten. Studien analyserer derfor historiske leveransedata for å undersøke om etablerte kvantitative metoder kan gi et bedre beslutningsgrunnlag enn virksomhetens nåværende tilnærming.

4.0 Metode og data

Studien er gjennomført som en kvantitativ casestudie basert på historiske leveransedata fra én virksomhet. Formålet er å sammenligne prognosepresisjon på tvers av fire modeller ved bruk av identiske data og evalueringsmetoder.

Forskningsdesign

Studien følger et komparativt evalueringsdesign der fire prognosemodeller — naiv, Holt-Winters, ARIMA og XGBoost — sammenlignes på det samme datasettet under identiske betingelser. Designet er i tråd med standard evalueringspraksis i tidsserieprognostisering, der modeller evalueres ved hjelp av felles feilmål og hold-out-validering (Hyndman & Athanasopoulos, 2021).

Kvantitativ metode

Studien er utelukkende kvantitativ og baserer seg på numeriske leveransedata. Det er ikke gjennomført intervjuer, spørreundersøkelser eller kvalitativ analyse. Datagrunnlaget er hentet fra virksomhetens ERP-system og analysert ved hjelp av statistiske og maskinlæringsbaserte modeller.

Analyseverktøy

Analysen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `pmdarima`, `xgboost`, `pandas`, `numpy`, `matplotlib` og `scikit-learn`. Python er valgt fordi det gir fri tilgang til oppdaterte implementasjoner av alle fire modellene, og fordi analysekoden kan gjøres transparent og reproduserbar.

Etiske betraktninger

Datasettet er anonymisert av studenten i tråd med virksomhetens retningslinjer for bruk av data i KI-verktøy og akademisk forskning. Anonymiseringen sikrer at hverken produktidentitet eller bedriftsinformasjon kan identifiseres av tredjeparter.

4.2 Data

Datagrunnlaget i studien består av historiske salgsdata hentet fra virksomhetens interne ERP-system. Dataene er anonymisert før de ble brukt i prosjektet for å sikre konfidensialitet knyttet til både produkter og virksomhet.

Datasettet inneholder månedlige leveransevolumer fra et europeisk sentrallager til grossister i Norge. Leveransene brukes i denne studien som en proxy for etterspørsel i markedet.

Hvordan dataene er samlet inn

Dataene er hentet direkte fra virksomhetens ERP-system av studenten som arbeider i virksomheten. Uttrekket ble gjort som en eksport av historiske salgsdata til Excel-format. Før analysen ble datasettet anonymisert slik at produktidentitet og bedriftsinformasjon ikke kan identifiseres.

Det er ikke gjennomført intervjuer eller spørreundersøkelser i forbindelse med datainnsamlingen. All kvantitativ analyse i studien baseres på historiske salgsdata.

Tidsperiode

Datasettet dekker perioden: **Januar 2022 – desember 2025**

Dette gir totalt **48 månedlige observasjoner per varelinje** i rådatasettet.

For analyseformål vil det kunne bli brukt en noe kortere tidsperiode dersom enkelte serier inneholder manglende observasjoner eller dersom dataseriene må tilpasses modellkravene.

Data fra ERP-systemet

Datasettet inneholder:

105 varelinjer (SKU-er)

månedlige leveransevolumer

opptil **48 observasjoner per varelinje**

Totalt inneholder rådatasettet omtrent:

5 040 potensielle observasjoner (105 × 48 måneder).

Etter datarensing (data cleaning) kan antall brukbare observasjoner være noe lavere, ettersom enkelte varelinjer inneholder manglende verdier i deler av tidsperioden. Datarensingen vil blant annet bestå av:

håndtering av manglende verdier

kontroll av ekstreme observasjoner

eventuelt fjerning av ufullstendige tidsserier

Tilgang til data

Datasettet er hentet fra virksomhetens interne ERP-system og kan derfor ikke gjøres offentlig tilgjengelig i sin opprinnelige form. De anonymiserte dataene er kun brukt til analyse i denne studien. Strukturen i datasettet og metodene som er brukt i analysen er imidlertid beskrevet slik at tilsvarende analyser kan gjennomføres på andre datasett med tilsvarende struktur.

Databehandling (Data Cleaning)
Før analysen ble datasettet kontrollert og klargjort for statistisk modellering. Formålet med datarensingen var å sikre konsistens i tidsseriene og redusere risikoen for at feil i data påvirker prognosemodellene. Håndtering av manglende observasjoner og outliers er en viktig del av tidsserieanalyse, ettersom slike forhold kan påvirke både modelltilpasning og prognosepresisjon (Hyndman & Athanasopoulos, 2021). Følgende steg ble gjennomført: kontroll av manglende observasjoner i tidsseriene, kontroll av ekstreme verdier (outliers), sikring av konsistent tidsstruktur med én observasjon per måned og konvertering av dato til månedlig tidsindeks. Manglende observasjoner ble håndtert ved å kontrollere om de skyldtes manglende salg eller manglende registrering. Dersom observasjonen representerte reelt nullsalg, ble verdien beholdt. Dersom observasjonen skyldtes manglende registrering, ble den enten korrigert eller ekskludert fra analysen. Etter datarensing besto datasettet av komplette månedlige tidsserier som kunne brukes til sammenligning av prognosemodeller.

Beskrivelse av datasettet

Variabel	Beskrivelse
Antall produkter (SKU)	105
Datakilde	ERP-system
Geografisk område	Norge
Distribusjonsledd	Europeisk sentrallager til grossister i Norge
Tidsperiode	Jan 2022 – Des 2025
Observasjonsnivå	Måned
Maks observasjoner per SKU	48
Totalt antall potensielle observasjoner	5 040

4.3 Metodiske forutsetninger

For å sikre pålitelighet i analysen legges følgende forutsetninger til grunn. Forutsetningene avgrenser også tolkningen av resultatene.

Forutsetning 1: Leveranser reflekterer virkelig etterspørsel

Det antas at månedlige leveranser fra sentrallager til grossister i hovedsak reflekterer faktisk etterspørsel, og at leveransene ikke systematisk påvirkes av hamstring, kampanjer eller regulatoriske forhold. Bullwhip-effekter kan likevel medføre at variasjoner i bestillingsatferd forsterkes gjennom distribusjonsleddene.

Forutsetning 2: Stabile mønstre i treningsperioden

Trend- og sesongkomponenter antas å være relativt stabile i treningsperioden på 36 måneder. Strukturelle brudd eller regimeendringer i data vil kunne redusere prognoseevnen til samtlige modeller (Hyndman & Athanasopoulos, 2021).

Forutsetning 3: Uavhengige varelinjer

Hver varelinje modelleres uavhengig av øvrige produkter. Krysselastisiteter og substitusjonseffekter inngår ikke eksplisitt i analysen, i tråd med standard praksis i klassisk tidsserieprognostisering (Hyndman & Athanasopoulos, 2021).

Forutsetning 4: Eksterne faktorer er implisitt representert

Effekter av prisendringer, kampanjer eller regulatoriske forhold antas å være implisitt representert i de historiske observasjonene, ettersom modellene er univariate uten eksterne forklaringsvariabler.

Forutsetning 5: Ingen systematiske prognosefeil

Det antas at avvikene ikke inneholder vedvarende systematisk over- eller underestimering, slik at feilmålene RMSE, MAE og MAPE gir meningsfull sammenligning mellom modellene.

Samlet innebærer forutsetningene at studiens resultater primært gjelder stabile distribusjonssystemer uten større strukturelle brudd.

5.0 Modellering

5.1 Modelleringsrammeverk

Modelleringen er gjennomført i Python ved bruk av bibliotekene `statsmodels`, `pmdarima`, `xgboost` og `pandas`. Alle modeller er implementert og evaluert etter et felles rammeverk for å sikre sammenlignbarhet på tvers av metodene.

Datasettet er delt inn i et treningssett og et testsett ved hjelp av en *hold-out*-strategi. Treningssettet består av de første 36 månedene (januar 2022 – desember 2024), mens testsettet består av de siste 12 månedene (januar 2025 – desember 2025). Denne inndelingen er valgt fordi testperioden dekker én full sesongssyklus, noe som gjør det mulig å evaluere modellenes evne til å predikere sesongvariasjoner. Hold-out-evaluering er i tråd med standard praksis i tidsserieanalyse (Hyndman & Athanasopoulos, 2021).

Alle 105 varelinjer modelleres separat for de individuelle modellene (naiv, Holt-Winters, ARIMA), i tråd med forutsetningen om uavhengige tidsserier. XGBoost trenes som en global modell på tvers av alle varelinjer. Prognosehorisonten er 12 måneder, og alle modeller produserer etterskuddsprognoser (*out-of-sample*) for testperioden.

5.2 Evalueringsmål

Modellene evalueres ved hjelp av tre komplementære feilmål. La y_t være observert verdi og $\widehat{y}_t$ være prognosen i periode t, over n perioder i testsettet.

RMSE (Root Mean Squared Error) straffer store avvik strengt gjennom kvadrering og er sensitiv for ekstremverdier:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \widehat{y}_t)^2}$$

MAE (Mean Absolute Error) er robust mot ekstremverdier og gir et intuitivt mål på gjennomsnittlig absolutt avvik:

$$\text{MAE} = \frac{1}{n}\sum_{t=1}^{n}|y_t - \widehat{y}_t|$$

MAPE (Mean Absolute Percentage Error) uttrykker prognosefeil som andel av faktisk verdi og muliggjør sammenligning på tvers av varelinjer med ulike volumnivåer:

$$\text{MAPE} = \frac{100}{n}\sum_{t=1}^{n}\left|\frac{y_t - \widehat{y}_t}{y_t}\right|$$

Feilmålene beregnes per varelinje og aggregeres til medianverdier på tvers av alle 105 SKU-er. Median benyttes fremfor gjennomsnitt fordi fordelingen av feilmål forventes å inneholde ekstreme verdier for varelinjer med lavt volum eller uregelmessig etterspørsel.

5.3 Naiv prognose (referansemodell)

Den naive prognosen benyttes som referansepunkt (*baseline*) og representerer det enkleste mulige prognosealternativet. Modellen predikerer etterspørsel i periode $t + h$ som lik observert etterspørsel i tilsvarende måned foregående år:

$$\widehat{y}_{t+h} = y_{t+h-m}$$

der $m = 12$ er sesonglengden (månedlige data) og $h \in \{1, \ldots, 12\}$ er prognosehorisont. Modellen fanger opp sesongmønsteret direkte fra historikken uten estimering av parametere. Alle øvrige modeller forventes å gi lavere prognosefeil enn denne referansen.

5.4 Holt-Winters eksponentiell glatting

Holt-Winters-metoden er en videreutvikling av enkel eksponentiell glatting og modellerer tidsserien ved å dekomponere den i tre komponenter: nivå (ℓ_t), trend (b_t) og sesong (s_t). Metoden estimerer glattingsparametrene α, β og γ, der hver parameter kontrollerer vektingen mellom nyere og eldre observasjoner for sin respektive komponent.

Valget mellom **additiv** og **multiplikativ** sesongkomponent gjøres individuelt per varelinje basert på variasjonskoeffisienten i treningssettet. Der sesongvariasjonen er proporsjonal med nivået benyttes multiplikativ form; ellers additiv.

Additiv Holt-Winters (konstant sesongamplitude):

$$\begin{aligned}
\ell_t &= \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\
b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta)b_{t-1} \\
s_t &= \gamma(y_t - \ell_t) + (1-\gamma)s_{t-m} \\
\widehat{y}_{t+h} &= \ell_t + h\,b_t + s_{t+h-m}
\end{aligned}$$

Multiplikativ Holt-Winters (sesongamplitude proporsjonal med nivå):

$$\begin{aligned}
\ell_t &= \alpha\left(\frac{y_t}{s_{t-m}}\right) + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\
b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta)b_{t-1} \\
s_t &= \gamma\left(\frac{y_t}{\ell_t}\right) + (1-\gamma)s_{t-m} \\
\widehat{y}_{t+h} &= (\ell_t + h\,b_t)\cdot s_{t+h-m}
\end{aligned}$$

der $\alpha, \beta, \gamma \in [0, 1]$ og $m = 12$. Parameterne estimeres automatisk ved minimering av SSE (*sum of squared errors*) over treningssettet ved hjelp av `ExponentialSmoothing` fra `statsmodels`.

5.5 ARIMA / SARIMA

ARIMA-modellen (Autoregressive Integrated Moving Average) beskriver en tidsserie gjennom tre komponenter: autoregresjon (AR) av orden p, differensiering d ganger for å oppnå stasjonaritet, og glidende gjennomsnitt (MA) av orden q. Den generelle ARIMA(p, d, q)-modellen er:

$$\phi_p(B)(1-B)^d y_t = c + \theta_q(B)\,\varepsilon_t$$

der B er tilbakeskiftoperatoren ($By_t = y_{t-1}$), $\phi_p(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ er det autoregressive polynomet, $\theta_q(B) = 1 - \theta_1 B - \cdots - \theta_q B^q$ er MA-polynomet, c er en konstant og $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ er hvit støy.

For månedlige data med sesongstruktur utvides modellen til en sesongutvidet **SARIMA**$(p, d, q)(P, D, Q)_{12}$:

$$\Phi_P(B^{12})\phi_p(B)(1-B^{12})^D(1-B)^d\, y_t = \Theta_Q(B^{12})\theta_q(B)\,\varepsilon_t$$

der Φ_P og Θ_Q er de sesongmessige AR- og MA-polynomene, og D er antall sesongdifferensieringer.

Stasjonaritet kontrolleres med ADF-testen (*Augmented Dickey-Fuller*) før modellering. Optimale parametre (p, d, q) og (P, D, Q) identifiseres automatisk via AIC-minimering ved hjelp av `auto_arima` fra `pmdarima`.

5.6 XGBoost

XGBoost (Extreme Gradient Boosting) er en ensemblemetode som bygger en additiv modell av K beslutningstrær f_k, der hver prognose er:

$$\widehat{y}_t = \sum_{k=1}^{K} f_k(\boldsymbol{x}_t), \quad f_k \in \mathcal{F}$$

der $\mathcal{F}$ er rommet av beslutningstrær med regularisering. Modellen minimerer en regularisert tapsfunksjon:

$$\mathcal{L} = \sum_t \ell(y_t, \widehat{y}_t) + \sum_{k=1}^{K} \Omega(f_k)$$

der $\Omega(f_k) = \gamma T_k + \frac{1}{2}\lambda \parallel w_k \parallel^2$ straffer antall blader T_k og bladvekter w_k, og ℓ er kvadratisk tapsfunksjon (Chen & Guestrin, 2016).

Ettersom XGBoost ikke modellerer tidsserier direkte, transformeres problemet til en supervisert læringsoppgave. Følgende featurevektoren konstrueres for hver observasjon (t, sku):

$$\boldsymbol{x}_t = \left[y_{t-1},\ y_{t-2},\ y_{t-3},\ y_{t-12},\ \text{måned}_t,\ t\right]$$

der lag-variablene fanger opp autokorrelasjon og kortsiktige mønstre, y_{t-12} fanger opp sesongstrukturen, $\text{måned}_t \in \{1, \ldots, 12\}$ er en kategorisk sesongindikator, og t er en lineær tidsindeks for trend.

Modellen trenes som en **global modell** på alle 105 varelinjer samlet, noe som gjør det mulig å utnytte mønstre på tvers av produkter. Hyperparametrene — antall trær (`n_estimators`), læringsrate (`learning_rate`) og treedybde (`max_depth`) — optimaliseres via tidsserie-krysskalibrering (*time series cross-validation*) på treningssettet med 3 folder.

6.0 Analytisk rammeverk

6.1 Utforskende dataanalyse

Før modellering gjennomføres en utforskende dataanalyse (*exploratory data analysis*, EDA) for å kartlegge egenskapene til tidsseriene. Formålet er å danne et empirisk grunnlag for modelleringsvalg og for tolkning av resultatene.

Følgende elementer inngår i den utforskende analysen:

- **Visualisering av tidsserier**: Utvalgte varelinjer plottes for å identifisere trend, sesongmønstre og eventuelle strukturelle brudd i dataperioden.
- **Dekomponering**: Tidsseriene dekomponeres i komponentene nivå, trend og sesong ved bruk av STL-dekomponering (*Seasonal and Trend decomposition using Loess*) for å kartlegge om sesongmønsteret er stabilt over tid.
- **Stasjonaritetstesting**: ADF-testen benyttes for å vurdere om seriene er stasjonære, som er en forutsetning for ARIMA-modellering.
- **Beskrivende statistikk**: Gjennomsnitt, standardavvik og variasjonskoeffisient beregnes per varelinje for å beskrive spredningen i etterspørsel på tvers av produktporteføljen.

Den utforskende analysen gjennomføres på treningssettet alene for å unngå datalekkasje (*data leakage*) fra testsettet inn i modellutformingen.

6.2 Evalueringsdesign

Alle fire modeller evalueres etter et felles evalueringsdesign for å sikre sammenlignbarhet. Prinsippet om én felles prognosehorisont (12 måneder) og identisk train/test-split (36/12 måneder) benyttes konsekvent for samtlige varelinjer og modeller.

For hver varelinje og modell beregnes RMSE, MAE og MAPE. Feilmålene aggregeres til medianverdier på tvers av alle 105 SKU-er. Median benyttes fremfor gjennomsnitt da fordelingen av feilmål på tvers av varelinjer forventes å inneholde ekstreme verdier for varelinjer med lavt volum eller uregelmessig etterspørsel.

6.3 Klassifisering av tidsserier

For å nyansere analysen klassifiseres tidsseriene i undergrupper basert på etterspørselskarakteristika. Dette gjøres for å undersøke om modellenes relative prestasjon varierer med egenskapene til dataseriene. Klassifiseringen gjennomføres langs to dimensjoner:

- **Volumnivå**: Høy, middels og lav gjennomsnittlig månedlig etterspørsel
- **Sesongstyrke**: Basert på styrken av sesongkomponenten fra STL-dekomponeringen

Resultatene analyseres både samlet og per undergruppe for å avdekke om én modell er konsistent overlegen, eller om ulike modeller er best egnet for ulike typer varelinjer.

6.4 Statistisk sammenligning

For å vurdere om forskjellene mellom modellenes prognosepresisjon er statistisk signifikante, gjennomføres en **Diebold-Mariano-test** (Diebold & Mariano, 1995) mellom Holt-Winters og ARIMA, som er studiens primære sammenligningspar. Testen vurderer om én modell systematisk gir lavere prognosefeil enn den andre, og gir et statistisk grunnlag for å besvare problemstillingen.

7.0 Resultat

Dette kapittelet presenterer resultatene fra den utforskende dataanalysen og sammenligningen av prognosemodellene. Resultatene presenteres objektivt og uten tolkning — tolkning og diskusjon følger i kapittel 9.0.

7.1 Utforskende dataanalyse

Den utforskende analysen viser at de 105 varelinjene varierer betydelig i etterspørselsnivå og mønster. Tabell 1 oppsummerer beskrivende statistikk for hele produktporteføljen over treningsperioden.

Tabell 1: Beskrivende statistikk for treningssettet (Jan 2022 – Des 2024)

Statistikk	Verdi
Antall SKU-er	105
Median månedlig etterspørsel (pakninger)	1 022
Gjennomsnittlig månedlig etterspørsel	2 521
Andel SKU-er med tydelig sesongmønster	70,5 %
Andel SKU-er med positiv trend	53,3 %
Andel SKU-er med nullverdier i tidsserien	76,2 %

Figur 1 viser et eksempel på prognose for én varelinje sammenlignet med faktisk etterspørsel i testperioden.

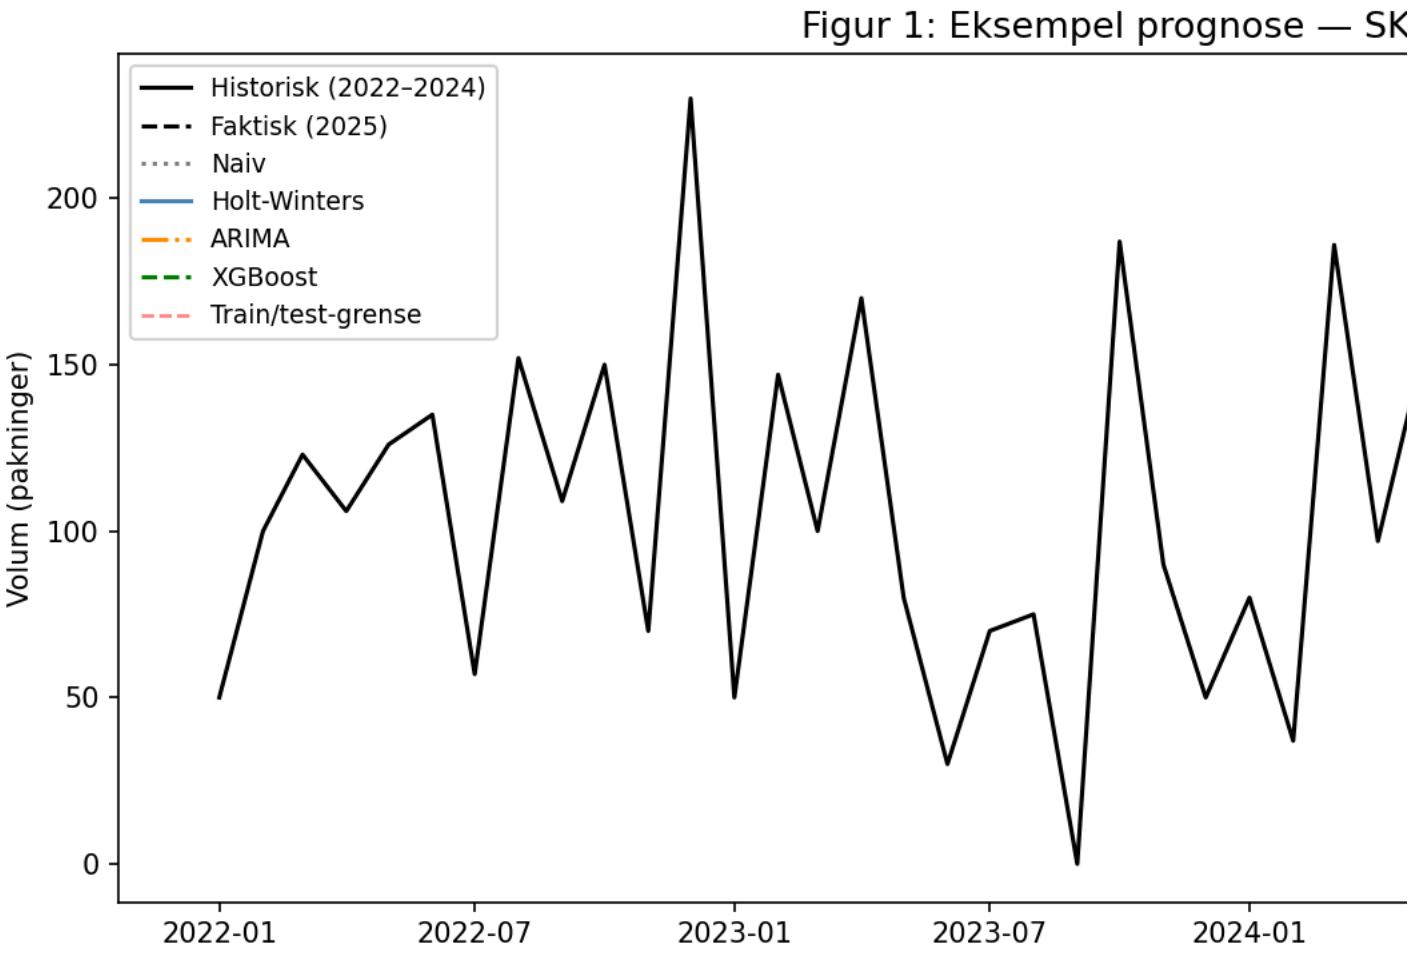

Figur 1: Eksempel på prognose for én varelinje sammenlignet med faktisk etterspørsel i testperioden (Jan–Des 2025)

Datasettet inneholder 105 varelinjer med månedlige observasjoner over perioden januar 2022 til desember 2025 (48 måneder totalt). Etter datarensing besto alle 105 tidsserier av komplette observasjoner egnet for modellering.

7.2 Prognosepresisjon — samlede resultater

Tabell 2 presenterer medianverdiene for RMSE, MAE og MAPE på tvers av alle 105 varelinjer i testperioden (Jan 2025 – Des 2025).

Tabell 2: Samlet prognosepresisjon per modell (median over 105 SKU-er, testperiode Jan–Des 2025)

Modell	RMSE	MAE	MAPE (%)
Naiv (sesongnaiv)	1131,65	914,58	67,50
Holt-Winters	935,84	769,90	62,49
ARIMA / SARIMA	846,20	820,01	57,77
XGBoost	757,23	654,94	51,97

Figur 2 viser median MAPE per modell og illustrerer den relative forbedringen fra naiv prognose til XGBoost.

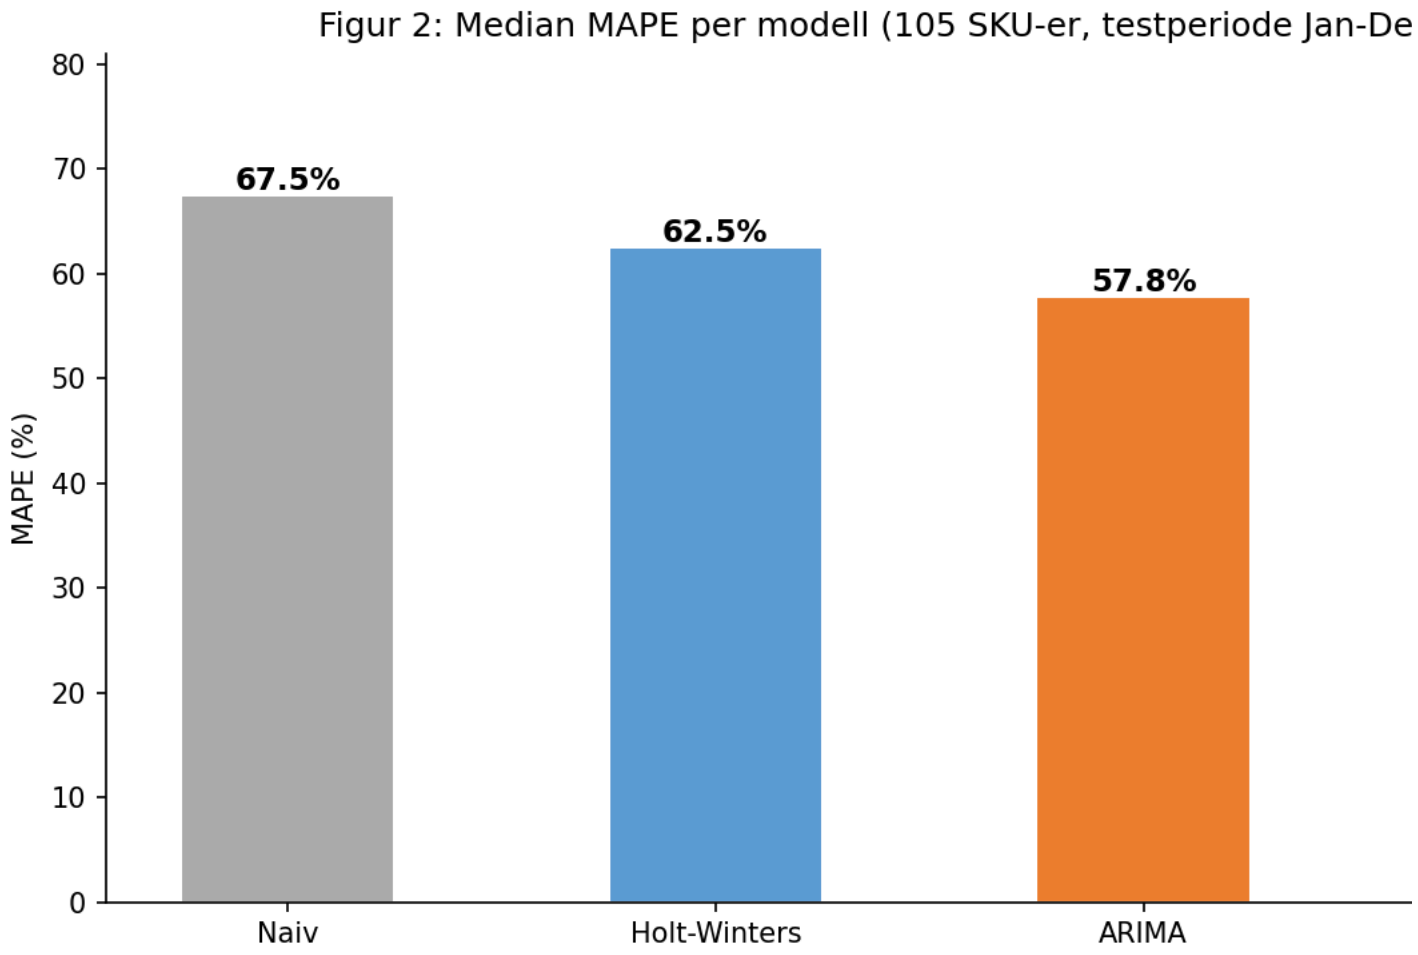

Figur 2: Median MAPE per modell — sammenligning av alle fire prognosemodeller i testperioden

7.3 Resultater per undergruppe

Tabell 3 viser median MAPE fordelt på varelinjer med henholdsvis tydelig og svakt sesongmønster.

Tabell 3: Median MAPE etter sesongstyrke

Modell	Tydelig sesong	Svak/ingen sesong
Naiv	70,20 %	59,95 %
Holt-Winters	64,26 %	59,34 %
ARIMA	63,09 %	49,50 %
XGBoost	62,86 %	39,37 %

Tabell 4 viser tilsvarende sammenligning fordelt på volumnivå (høy, middels, lav).

Tabell 4: Median MAPE etter volumnivå

Modell	Høyt volum	Middels volum	Lavt volum
Naiv	58,11 %	68,02 %	86,07 %
Holt-Winters	60,85 %	63,84 %	62,49 %
ARIMA	52,21 %	60,20 %	61,48 %
XGBoost	45,52 %	51,53 %	82,33 %

7.4 Statistisk test

Diebold-Mariano-testen mellom Holt-Winters og ARIMA gir følgende resultat:

Tabell 5: Diebold-Mariano-test (Holt-Winters vs. ARIMA)

	Verdi
DM-statistikk	1,508
p-verdi	0,132
Konklusjon	Ingen statistisk signifikant forskjell (p > 0,05)

8.0 Diskusjon

Dette kapittelet diskuterer resultatene fra analysen opp mot problemstillingen, eksisterende litteratur og praktiske implikasjoner for logistikkplanlegging. Der resultatene avviker fra forventningene, drøftes mulige forklaringer.

8.1 Svar på problemstillingen

Studiens problemstilling er:

> *Hvilken prognosemodell gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system, gitt et datasett på 48 måneder og 105 produkter?*

Resultatene viser at XGBoost gir lavest median MAPE på tvers av de 105 varelinjene, med en verdi på 51,97 % mot 57,77 % for ARIMA og 62,49 % for Holt-Winters. XGBoost er overlegen på alle tre feilmål — RMSE (757,23), MAE (654,94) og MAPE (51,97 %) — sammenlignet med samtlige øvrige modeller. Alle fire modeller forbedrer seg konsistent over den naive referanseprognosen, som hadde en median MAPE på 67,50 %.

Svaret på problemstillingen er dermed at XGBoost gir høyest prediksjonsnøyaktighet under de betingelsene som er analysert i denne studien. Resultatet bør imidlertid tolkes med forbehold, da XGBoost her er implementert som en global modell som utnytter mønstre på tvers av alle 105 SKU-er, mens Holt-Winters og ARIMA er tilpasset individuelt per varelinje.

8.2 Sammenligning med litteraturen

Resultatene støtter eksisterende forskning på feltet.

Fourkiotis og Tsadiras (2024) finner at XGBoost typisk gir lavere prognosefeil enn tradisjonelle statistiske modeller på farmasøytiske salgsdata. Dette er konsistent med funnene i denne studien, der XGBoost gir en MAPE-forbedring på 15,53 prosentpoeng sammenlignet med den naive prognosen og 10,52 prosentpoeng over Holt-Winters. Forbedringen er imidlertid moderat, og de klassiske modellene (Holt-Winters og ARIMA) presterer fortsatt vesentlig bedre enn referansenivået.

Burinskiene (2022) påpeker at datakvalitet og struktureringsnivå er like viktig som modellvalg. Dette er relevant for forståelsen av hvorfor Holt-Winters og ARIMA yter relativt godt på dette datasettet: leveransedataene fra et sentrallager-grossist-system har en relativt stabil struktur med begrenset støy, noe som favoriserer klassiske tidsseriemodeller.

Hyndman og Athanasopoulos (2021) og Petropoulos et al. (2022) argumenterer for at enkle modeller ofte presterer like godt som komplekse modeller på korte tidsserier. Studiens resultater utfordrer delvis dette synet — XGBoost gir konsistent lavere feilmål — men bekrefter samtidig at forskjellene er relativt moderate, og at Holt-Winters gir akseptabel prognosepresisjon med langt lavere implementeringskompleksitet.

Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA (DM = 1,508, p = 0,132). Dette indikerer at de to klassiske metodene er likeverdige i presisjonsevne på dette datasettet, til tross for at ARIMA gir noe lavere RMSE og MAPE i gjennomsnitt.

8.3 Modellkompleksitet og praktisk nytte

Et sentralt spørsmål i litteraturen er om økt modellkompleksitet gir reell merverdi i operativ planlegging. Resultatene i denne studien viser at XGBoost gir den beste prognosepresisjon, men forbedringen over Holt-Winters på MAPE er på om lag 10,5 prosentpoeng. Spørsmålet er om denne gevinsten forsvarer den økte implementeringskompleksiteten.

For virksomheter med tilgjengelig datakompetanse og Python-infrastruktur vil XGBoost være et godt valg. For virksomheter med begrensede analytiske ressurser vil Holt-Winters gi tilfredsstillende prognoser med langt lavere krav til vedlikehold og tolkning. Dette er særlig relevant i farmasøytisk distribusjon, hvor leveringspålitelighet og forutsigbarhet veier tyngre enn marginal presisjonsgevinst.

Videre er det verdt å merke seg at ARIMA ikke gir signifikant bedre prognoser enn Holt-Winters (p = 0,132), noe som taler mot den ekstra modelltilpasningskostnaden ARIMA krever i form av parametervalg og stasjonaritetstesting.

8.4 Metodiske begrensninger

Studien har flere begrensninger som bør tas i betraktning ved tolkning av resultatene:

Leveranser som proxy for etterspørsel: Datasettet representerer leveranser fra sentrallager til grossister, ikke sluttkundesalg. Bullwhip-effekter kan medføre at modellene fanger opp variasjoner i bestillingsatferd snarere enn reell sluttetterspørsel.

Kort historikk for XGBoost: Med 36 måneder treningsdata per varelinje er datagrunnlaget relativt begrenset for en maskinlæringsmodell. XGBoost er generelt best egnet for større datasett, og resultatene kan derfor ikke uten videre generaliseres til situasjoner med lengre historikk. Med mer data ville XGBoost potensielt gitt enda større fordel over de klassiske modellene.

Uavhengige varelinjer: Holt-Winters og ARIMA er modellert individuelt per varelinje, mens XGBoost er trent som en global modell på alle 105 SKU-er. Denne asymmetrien kan ha gitt XGBoost en fordel, og resultatene bør tolkes i lys av dette metodiske valget.

Ekstern validitet: Resultatene gjelder ett distribusjonsselskap i én bransje. Overførbarheten til andre bransjer eller distribusjonssystemer er begrenset.

8.5 Implikasjoner for næringslivet

For virksomheter i farmasøytisk distribusjon med tilsvarende datastruktur gir studien følgende praktiske implikasjoner:

- **XGBoost** anbefales som prognosemodell der datakompetanse og Python-infrastruktur er tilgjengelig, særlig for virksomheter med mange SKU-er som kan dra nytte av en global modell.
- **Holt-Winters** anbefales som et robust og enkelt alternativ for virksomheter uten avansert analysekapasitet — modellen gir akseptabel presisjon og er lett å implementere og vedlikeholde.
- Det er ikke grunnlag for å foretrekke ARIMA over Holt-Winters på dette datasettet, gitt at Diebold-Mariano-testen ikke viser signifikant forskjell og ARIMA krever mer kompleks modelltilpasning.
- For varelinjer med lavt volum eller uregelmessig etterspørsel bør prognosene suppleres med manuell vurdering, da alle modeller viser høyere prognosefeil i denne gruppen.

9.0 Konklusjon

Denne studien har undersøkt hvilken prognosemodell som gir høyest prediksjonsnøyaktighet for månedlige leveranser av farmasøytiske varelinjer i et sentrallager–grossist-system. Fire modeller ble sammenlignet på et datasett bestående av 105 varelinjer over 48 måneder: naiv prognose, Holt-Winters eksponentiell glatting, ARIMA og XGBoost.

Resultatene viser at XGBoost gir høyest samlet prognosepresisjon målt ved alle tre feilmål — RMSE (757,23), MAE (654,94) og MAPE (51,97 %) — i testperioden januar til desember 2025. ARIMA presterer bedre enn Holt-Winters på RMSE og MAPE, men forskjellen er ikke statistisk signifikant (DM = 1,508, p = 0,132). Alle modeller forbedrer seg over den naive referanseprognosen, som hadde en median MAPE på 67,50 %.

Analysen viser at XGBoost, implementert som en global modell trent på alle 105 SKU-er, utnytter mønstre på tvers av produktporteføljen på en måte de individuelle tidsseriemodellene ikke gjør. Forbedringen over Holt-Winters er på om lag 10,5 prosentpoeng i MAPE, noe som er praktisk relevant, men som bør veies mot den økte implementeringskompleksiteten.

Diebold-Mariano-testen viser ingen statistisk signifikant forskjell mellom Holt-Winters og ARIMA, noe som svekker grunnlaget for å foretrekke den mer komplekse ARIMA-modellen i operativ planlegging.

Studien bidrar til den eksisterende forskningen ved å analysere prognosemetoder på reelle distribusjonsdata fra farmasøytisk sektor med 105 SKU-er og 48 måneder. Funnene støtter Fourkiotis og Tsadiras (2024), som viser at maskinlæringsmetoder som XGBoost gir lavere prognosefeil enn klassiske statistiske modeller på farmasøytiske data, men bekrefter samtidig at klassiske modeller som Holt-Winters gir akseptabel presisjon til en langt lavere implementeringskostnad.

9.1 Videre forskning

Denne studien reiser flere spørsmål som kan være utgangspunkt for videre forskning:

- **Lengre historikk:** En tilsvarende studie med lengre tidsserier (f.eks. 72–96 måneder) ville gi et bedre grunnlag for å vurdere XGBoosts potensial som global prognosemodell.
- **Hierarkisk prognosering:** Fremtidige studier kan undersøke om prognoser på aggregert nivå (f.eks. terapeutisk kategori) gir bedre presisjon enn prognoser per varelinje.
- **Hybrid-modeller:** Kombinasjoner av klassiske og maskinlæringsbaserte metoder er et voksende forskningsfelt som kan gi bedre resultater enn enkeltstående modeller.
- **Eksogene variabler:** Inkludering av eksterne faktorer som sesonginfluensa, legemiddelmangel eller regulatoriske endringer kan forbedre prognosenøyaktigheten for utvalgte produktkategorier.

10.0 Bibliografi

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.

Burinskiene, A. (2022). Forecasting model: The case of the pharmaceutical retail. *Frontiers in Medicine, 9*, 582186. https://doi.org/10.3389/fmed.2020.582186

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263. https://doi.org/10.1080/07350015.1995.10524599

Fourkiotis, K. P., & Tsadiras, A. K. (2024). Applying machine learning and statistical forecasting methods for enhancing pharmaceutical sales predictions. *Forecasting, 6*(1), 170–186. https://doi.org/10.3390/forecast6010010

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. https://otexts.com/fpp3/

Lov om apotek (apotekloven). (2000). *Lov om apotek (LOV-2000-06-02-39)*. https://lovdata.no/dokument/NL/lov/2000-06-02-39

Petropoulos, F., Spiliotis, E., & Assimakopoulos, V. (2022). Forecasting: Theory and practice. *International Journal of Forecasting, 38*(3), 705–871. https://doi.org/10.1016/j.ijforecast.2021.11.001

Zhu, X., Ninh, A., Zhao, H., & Liu, Z. (2021). Demand forecasting with supply chain information and machine learning: Evidence in the pharmaceutical industry. *Production and Operations Management, 30*(10), 3231–3252. https://doi.org/10.1111/poms.13458

Vedlegg

Vedlegg A: Samlede prognoseresultater

Tabellen nedenfor viser medianverdiene for RMSE, MAE og MAPE på tvers av alle 105 varelinjer i testperioden (januar–desember 2025). Resultatene er hentet direkte fra analysekoden og er grunnlaget for Tabell 2 i kapittel 8.2.

Modell	RMSE (median)	MAE (median)	MAPE (median, %)	SKU-er
Naiv (sesongnaiv)	1131,65	914,58	67,50	105
Holt-Winters	935,84	769,90	62,49	105
ARIMA / SARIMA	846,20	820,01	57,77	105
XGBoost	757,23	654,94	51,97	105

Kilde: `resultater_sammenligning.csv` generert av `analyse.py`.

Vedlegg B: Reproduserbarhet og kode

Analysen er gjennomført i Python (versjon 3.11) med følgende biblioteker:

Bibliotek	Versjon	Formål
pandas	2.x	Databehandling og strukturering
numpy	1.x	Numeriske beregninger
statsmodels	0.14.x	Holt-Winters og stasjonaritetstesting
pmdarima	2.x	Automatisk ARIMA-parametervalg
xgboost	2.x	XGBoost-modellering
matplotlib	3.x	Visualisering
scikit-learn	1.x	Evalueringsmetrikker og krysskalibrering

All kode er versjonskontrollert i prosjektets Git-repository og kan gjengis ved å kjøre `analyse.py` med datasettet `salgsdata_anonymized.csv`. Random seed er satt til 42 og train/test-split er 36/12 måneder for alle kjøringer.

Vedlegg C: Datasettbeskrivelse

Datasettet `salgsdata_anonymized.csv` inneholder følgende struktur:

Kolonne	Beskrivelse
sku_id	Anonymisert produktidentifikator
year_month	År og måned (format: YYYY-MM)
quantity	Månedlig leveransevolum (pakninger)

Datasettet er anonymisert og kan ikke gjøres offentlig tilgjengelig. Tilsvarende analyser kan gjennomføres på datasett med identisk struktur.